

# Master Recherche Mathématiques et Applications

Spécialité : SYSTÈMES DYNAMIQUES ET SIGNAUX

Soutenu par : Christophe RIGAUD

le 7 juillet 2011

Au sein de l’Institut des Sciences et Techniques de l’Ingénieur d’Angers

## Interprétation d’images et graphe conceptuel intégrant des connaissances topologiques et photométriques

Jury:

Président :	L. Hardouin	Professeur Université d’Angers
Examinateurs :	L. Autrique	Professeur Université d’Angers
	F. Chapeau Blondeau	Professeur Université d’Angers
	J.L. Boimond	Professeur Université d’Angers
	J.B. Fasquel	MCF Université d’Angers
	C. Jean-Guillaume	MCF Université d’Angers
	M. Lhommeau	MCF Université d’Angers
	D.Rousseau	MCF Université d’Angers

Encadrant: Jean-Baptiste FASQUEL



LABORATOIRE D’INGÉNIERIE DES SYSTÈMES AUTOMATISÉS  
EA 4094 - Université d’Angers

Je soussigné Christophe Rigaud déclare être pleinement conscient que le plagiat de documents ou d'une partie d'un document publiés sur toutes formes de support, y compris l'internet, constitue une violation des droits d'auteur ainsi qu'une fraude caractérisée. En conséquence, je m'engage à citer toutes les sources que j'ai utilisées pour écrire ce rapport.

Signature :

# Remerciements

*Je tiens à remercier le laboratoire LISA, son directeur Jean Louis Boimond, les enseignant-chercheurs, les doctorants et les administratifs de m'avoir accueilli et épaulé tout au long de ce stage.*

*Je remercie plus particulièrement mon tuteur de stage, Jean-Baptiste Fasquel, pour la richesse du sujet proposé, l'encadrement irréprochable, sa disponibilité et la correction de ce rapport.*

*Merci également à Laurent Hardouin pour la qualité des enseignements et l'encadrement de ce master SDS. Je n'oublie pas le soutien pour une poursuite en doctorat qu'il m'a apporté, tout comme mon tuteur.*

*J'adresse un clin d'œil particulier à mes chers collègues de laboratoire qui ont, malgré la différence de parcours, su contribuer à une ambiance de travail exceptionnelle. Merci à Antoine, Alban, Floran, Gheotry, Yann et Vincent.*

# Table des matières

<b>1</b>	<b>Introduction</b>	<b>1</b>
1.1	Contexte et objectif . . . . .	1
1.2	Problématique . . . . .	1
1.3	État de l'art . . . . .	2
1.4	Organisation de l'étude . . . . .	3
<b>2</b>	<b>Représentation des connaissances, processus d'analyse et inférence</b>	<b>4</b>
2.1	Représentation des connaissances . . . . .	4
2.1.1	Graphe topologique et photométrique . . . . .	4
2.1.2	Relations : illustration dans le cas topologique . . . . .	5
2.2	Intégration du processus d'analyse séquentiel . . . . .	6
2.3	Inférence et topologie : région d'intérêt . . . . .	7
2.4	Inférence et photométrie . . . . .	7
2.4.1	Nombre de classes . . . . .	8
2.4.2	Identification des lobes . . . . .	12
2.5	Discussion : limites et perspectives . . . . .	13
<b>3</b>	<b>Évaluation</b>	<b>14</b>
3.1	Algorithme considéré . . . . .	14
3.2	Élimination des données polluantes . . . . .	15
3.3	Réduction de la quantité de données à traiter . . . . .	17
3.4	Connaissance du nombre de classe à priori . . . . .	18
3.5	Relations photométriques et initialisation des centroïdes . . . . .	19
<b>4</b>	<b>Application</b>	<b>21</b>
4.1	Introduction . . . . .	21
4.2	Cadre expérimental . . . . .	22
4.2.1	Données . . . . .	22
4.2.2	Mode opératoire . . . . .	24
4.2.3	Fenêtrage . . . . .	24
4.3	Scénario 1 : les tumeurs hépatiques . . . . .	25
4.3.1	Recherche du nombre de classes à priori . . . . .	25
4.3.2	Identification des classes . . . . .	26
4.3.3	Détermination du fenêtrage . . . . .	26
4.4	Scénario 2 : les vaisseaux hépatiques . . . . .	27
4.4.1	Identification des classes . . . . .	27
4.4.2	Détermination du fenêtrage . . . . .	28
<b>5</b>	<b>Conclusion</b>	<b>29</b>
<b>Annexes</b>		<b>31</b>

# 1 Introduction

## 1.1 Contexte et objectif

Les travaux présentés dans ce document ont été réalisés au cours d'un stage de master recherche de cinq mois qui s'est déroulé au sein du laboratoire LISA de l'école d'ingénieur ISTIA à Angers. Plus particulièrement dans le contexte de l'activité de recherche de l'analyse d'images pour l'aide au diagnostic. Il fait suite à une recherche bibliographique sur "l'interprétation d'images et graphe conceptuel intégrant des connaissances topologiques et photométriques".

L'objectif de ce stage est d'utiliser des notions conceptuelles non quantitatives, topologiques et photométriques, pour l'interprétation d'images synthétiques puis médicales. Le bénéfice attendu est d'optimiser la segmentation et le fenêtrage<sup>1</sup> (rendu visuel) d'une région d'intérêt (e.g. tumeur).

## 1.2 Problématique

Nous proposons d'interpréter des images en combinant des informations topologiques [10, Fasquel] et photométriques non quantitatives. Un exemple de situation où ce type d'information pourrait être avantageusement exploité serait celui illustré par la figure 1.1a. Cet exemple concerne le rendu volumique d'une image médicale. Le choix de la fenêtre de rendu (une plage d'intensités à afficher) est crucial pour améliorer la perception d'une structure donnée. Dans ce cas, on cherche à rendre le réseau vasculaire, supposant que l'on dispose du masque des os. Sachant que le réseau vasculaire n'est pas inclus dans les os (information topologique à priori), on peut tout simplement retirer de l'image le volume relatif au os afin de faciliter la visualisation du réseau vasculaire (figure 1.1b). Par ailleurs, dans l'hypothèse où le réseau vasculaire est plus clair que le tissu du foie (information photométrique que l'on retrouve visuellement sur la figure 1.1b), on peut modifier le fenêtrage de manière à afficher que les tissus qui ont une intensité supérieure à ceux du foie (voir figure 1.1c).

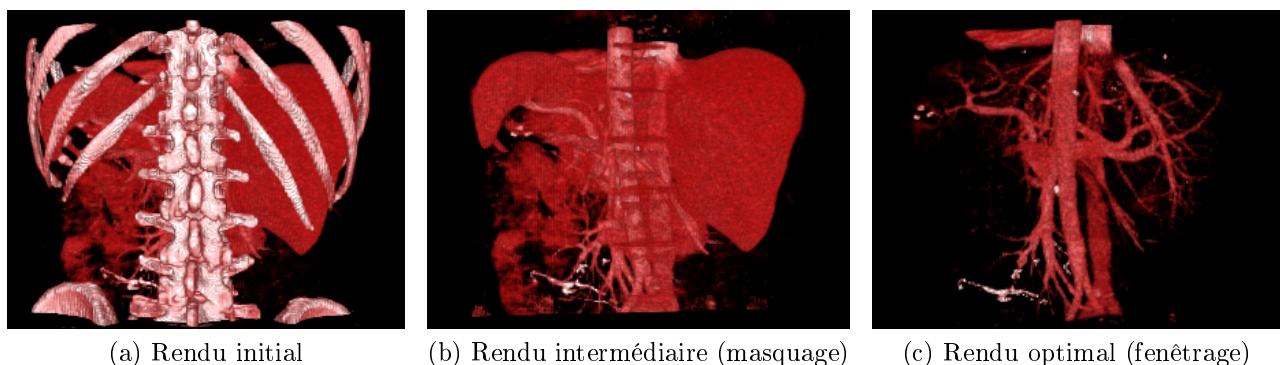


FIGURE 1.1 – Rendu manuel du réseau vasculaire

---

1. Le fenêtrage est le fait de considérer qu'une fraction de la dynamique d'une image (e.g. une section d'un histogramme d'image), on l'utilise souvent pour faciliter la visualisation ou les traitements d'une image.



### 1.3. ÉTAT DE L'ART

Cet exemple peut nous amener à nous poser les questions suivantes :

Si l'on considère une image en niveaux de gris, contenant une région *A* et une région *B* comme sur la figure 1.2, comment représenter et utiliser, pour l'interprétation automatique d'images, des concepts non quantitatifs tels que :

- La région *A* recouvre-t-elle la région *B* (topologie) ?
- La région *A* est-elle plus claire que la région *B* (photométrie) ?

Quels en sont les bénéfices ?

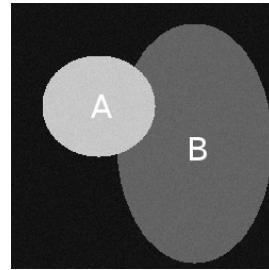


FIGURE 1.2 – Représentation synthétique des régions.

On s'intéressera à ces questions dans le cas d'un processus d'interprétation séquentiel de l'image où chaque étape conduira à la compréhension d'une région de l'image (i.e. segmentation et identification). Compte tenu de ces questions, la problématique de notre travail peut être modélisée par la figure suivante :

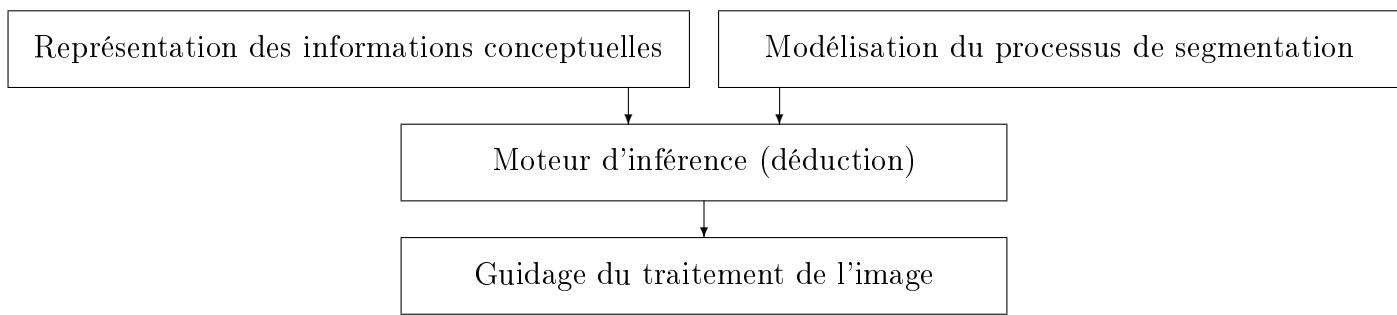


FIGURE 1.3 – Problématique et entités associées.

## 1.3 État de l'art

### Stratégie d'analyse d'image

Plusieurs approches de segmentations automatiques d'images ont déjà été mises à l'épreuve. La première consiste à considérer l'image dans son ensemble. L'idée est de concevoir un seul algorithme permettant de segmenter toutes les structures d'une image [16, Moreno][14, Kobashi]. Il est néanmoins courant que toutes les régions d'une images ne puissent pas être segmentées avec



un seul algorithme. Il est donc souvent plus réaliste de concevoir un algorithme spécifique à chacune des structures : c'est l'approche séquentielle ou itérative. Elle consiste à segmenter les structures les une après les autres avec un algorithme spécifique à chacune d'elles. Pour segmenter une structure donnée, il est pertinent de s'appuyer sur les informations relatives aux structures préalablement segmentées. Typiquement, il peut s'agir de l'intégration d'une région d'intérêt permettant de délimiter une zone de recherche pour la structure à segmenter [11, Hudelot][10, Fasquel].

### Informations conceptuelles

L'utilisation d'informations à priori est un moyen d'anticiper le contenu d'une image et donc d'en optimiser son traitement. En analyse d'image guidée par des informations à priori abstraites, les travaux récemment réalisés se focalisent sur des informations spatiales. Il peut s'agir de relations entre les structures de type topologiques (e.g. inclusion, recouvrement, adjacence) [10, Fasquel][9, Egenhofer][11, Hudelot] ou bien relatives à des notions de direction et de distance [11, Hudelot]. Un inconvénient des informations de distance et de direction est leurs aspects quantitatifs. Ceci implique la détermination de paramètres qui doivent être adaptés à l'application considérée. Ceci est notamment le cas des récents travaux de [11, Hudelot], où les informations de distance et de direction sont manipulées en utilisant la logique floue, ceci induisant une phase d'apprentissage “*fuzzy model learning*”.

Ces représentations conceptuelles (ontologiques<sup>2</sup> [12, Atif]) sont encore peu étudiées en interprétation d'image “*the development of ontology-based methods for image interpretation is still in its infancy*” [11, Hudelot, p.1929]. Il demeure une difficulté majeure lors de leurs applications au niveau des algorithmes d'analyses d'images : “*there still exists a large gap between the semantic interpretation of a medical image and its low-level features*” [8, Deruyver, p.1245]. Comme récemment souligné dans [11, Hudelot], ce type de connaissance est généralement utilisé dans des contextes différents de l'interprétation d'images, tel que l'annotation d'images.

A notre connaissance, il n'y a pas eu de travaux relatifs à l'analyse d'images guidée par le couplage d'informations conceptuelles topologiques et photométriques non quantitatives, ceci constituant une première originalité de l'orientation de nos travaux.

## 1.4 Organisation de l'étude

L'étude est organisée selon trois aspects correspondant aux volets : formalisation, évaluation et application. Le premier aspect (chapitre 2) est dédié à la formalisation en matière de représentation des connaissances et du moteur d'inférence. En ce qui concerne le moteur d'inférence, il s'agit d'établir les relations permettant de déduire, à partir de connaissances à priori sur l'image, des informations bénéfiques au traitement de l'image.

Le second aspect (chapitre 3) se focalise sur l'évaluation des bénéfices des informations déduites, dans le cas d'un algorithme particulier, le *K-Means clustering*, couramment utilisé en traitement d'images. Le dernier aspect (chapitre 4) est dédié à l'illustration du bénéfice de ce travail dans un cadre applicatif bien particulier relatif à la visualisation d'images médicales.

---

2. L'ontologie constitue en soi un modèle de données représentatif d'un ensemble de concepts dans un domaine, ainsi que des relations entre ces concepts. “L'ontologie est aux données ce que la grammaire est au langage” [http://fr.wikipedia.org/wiki/Ontologie\\_\(informatique\)](http://fr.wikipedia.org/wiki/Ontologie_(informatique))

# 2 Représentation des connaissances, processus d'analyse et inférence

## 2.1 Représentation des connaissances

La représentation des connaissances se base sur un graphe conceptuel où les noeuds sont associés aux différentes entités supposées présentes dans l'image. Les arcs reliant les noeuds représentent les relations (e.g. à gauche, à droite, inclus). Ce type de représentation a notamment été récemment considéré par [8, Deruyver, p.1246] et [10, Fasquel] et facilite la compréhension : “*Graph techniques permit to represent image objects and scenes in very natural way*” [20, Sanfeliu].

Les définitions des notations qui vont suivre sont fournies en annexe 1.

### 2.1.1 Graphe topologique et photométrique

Considérons une image synthétique  $I$  (fig. 2.1a) composée de  $N + 1$  régions (trois régions + le fond) correspondant à un ensemble  $S = \{0, 1, 2, 3\}$ . Si l'on segmente cette image, on obtient une image segmentée dans laquelle on devrait obtenir  $N + 1$  régions  $X$  de noeuds  $u : X(u)$ ,  $u \in S$ . L'image segmentée entière peut être considérée comme une région  $X(u = 0)$  contenant toutes les autres (racine). L'ensemble des régions constitue également l'image  $I = \{X(u) \mid u \in S\}$ .

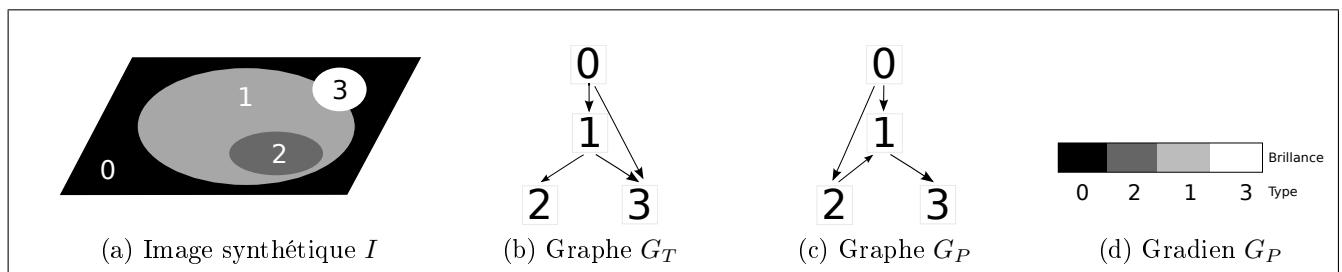


FIGURE 2.1 – Exemple d'une image et des graphes conceptuels associés.

Selon l'image 2.1a, l'ensemble  $S$  est égal à  $\{0, 1, 2, 3\}$ . Sur le graphe 2.1b on représente les inclusions partielles et totales des régions. On voit que la région 2 est complètement incluse dans 1, qui est elle-même incluse dans 0. La région 3 quand à elle est incluse partiellement dans 1 et 2. Cette information se traduit par deux arcs entrant sur le noeud 3 (fig. 2.1b). Dans le second graphe (fig. 2.1c), on représente les relations d'intensité lumineuse caractérisées par des arcs entrants (plus clair que) et sortant (plus sombre que). On retrouve par lecture du graphe, que 0 est la région la plus sombre (aucun arc entrant) et 3 la plus claire (aucun arc sortant).

La disposition spatiale des noeuds est identique pour les deux graphes pour souligner leurs différences limitées aux arcs qui les composent. Une autre représentation équivalente des informations photométriques peut être la figure 2.1d où l'on positionne les étiquettes des régions selon un gradient de niveaux de gris.



Par la suite, selon si les arcs traduisent une information topologique ou photométrique, nous aurons deux types de graphes, respectivement symbolisés par  $G_T$  (fig. 2.1b) et  $G_P$  (fig. 2.1c), reposant sur les mêmes noeuds mais se distinguant selon les arcs :

- Topologique :  $G_T = (S, A_T)$
- Photométrique :  $G_P = (S, A_P)$

Où  $S$  est l'ensemble des noeuds (types) et  $A_x$  l'ensemble des arcs les reliant.

Nous nous appuierons sur le formalisme de [10, Fasquel] en changeant quelques notations de sorte à rester cohérent avec notre étude. En effet dans son travail, il n'y avait pas de distinction de type d'arc car seule l'information topologique était considérée. L'intégration de la photométrie nécessite donc d'affiner les notations. On remplace  $F$  par  $G_T$  (pour graphe topologique), on utilise les notions de “prédécesseurs/successeurs” au lieu de “pères/fils” et on change l'orientation des arcs du graphe topologique.

### 2.1.2 Relations : illustration dans le cas topologique

Pour tous les éléments  $i$  contenu dans l'ensemble  $S$ ,  $G_T^{+1}(i)$  est un sous ensemble de  $S$  qui contient les “successeurs” directs (à une distance de +1) de  $i$ ,  $G_T^{-1}(i)$  ses prédécesseurs directs. Notons  $G_T^{-1}(0) = \emptyset$  et  $\forall i \in S$ ,  $G_T(i) \subseteq S$ . Une autre notation  $G_T^{-\infty}(i)$ , représente tous les “prédécesseurs” (jusqu'à la racine du graphe) d'un type  $i$ , par exemple, sur la figure 2.2,  $G_T^{-\infty}(4) = \{2, 0\}$ .

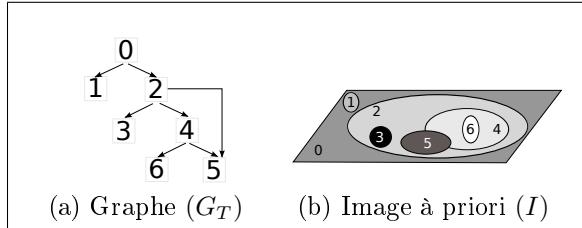


FIGURE 2.2 – Exemple de représentation d'informations topologiques à priori.

Le graphe 2.2a représente un ensemble  $S = \{0, 1, 2, 3, 4, 5, 6\}$  ayant des relations topologiques particulières définies par les arcs  $A_T$ , associées à une notion de recouvrement total ou partiel. On peut aisément déterminer les régions contenues (même partiellement) dans une région donnée en utilisant la notion de “prédécesseurs” :  $G_T^{-1}(0) = \emptyset$ ,  $G_T^{-1}(1) = \{0\}$ ,  $G_T^{-1}(2) = \{0\}$ ,  $G_T^{-1}(3) = \{2\}$ ,  $G_T^{-1}(4) = \{2\}$ ,  $G_T^{-1}(5) = \{2, 4\}$ ,  $G_T^{-1}(6) = \{4\}$ .

Ou inversement, en utilisant la notion de “successeurs” :  $G_T^1(0) = \{1, 2\}$ ,  $G_T^1(1) = \emptyset$ ,  $G_T^1(2) = \{3, 4, 5\}$ ,  $G_T^1(3) = \emptyset$ ,  $G_T^1(4) = \{5, 6\}$ ,  $G_T^1(5) = \emptyset$ ,  $G_T^1(6) = \emptyset$ .

Les informations à priori dépendent donc d'un ensemble de types ( $S$ ) qui ont des propriétés d'inclusion (arcs  $A_T$  dans  $G_T$ ), et de l'image ( $I$ ). On les note  $C = \{G_T, I\}$ .

En considérant l'imagerie médicale comme domaine d'application, on peut associer les éléments de  $S$  à des structures anatomiques (e.g. foie, rate) ou pathologiques (e.g. tumeur hépatique), ou bien à des structures relatives au système d'imagerie (e.g. table sur laquelle le patient est placé lors de l'acquisition de l'image). Ainsi, on pourrait par exemple assimiler ces régions à l'acquisition (0), la table sur laquelle est placée le patient dans l'imageur (1), le corps (2), la rate (3), le foie



(4), un vaisseau hépatique (5) et une tumeur du foie (6).  $G_T^{-1}(5) = \{4, 2\}$  signifierait donc que le vaisseau hépatique est contenu par la région du foie et du corps mais pas par celle de la rate par exemple.

## 2.2 Intégration du processus d'analyse séquentiel

Dans le cadre d'un processus d'analyse séquentiel, il s'agit d'intégrer l'information relative aux régions déjà segmentées : les étapes de segmentation suivantes prennent alors en compte le contexte, à savoir les informations (contextuelles) sur les régions déjà identifiées [10, Fasquel]. Les informations contextuelles se distinguent des précédentes par un indice de temps qui s'apparente aux itérations. On les notera  $C_t = \{G_{T,t}, I_t\}$  avec  $G_{T,t} = (S_t, A_t)$ .

$G_{T,t}$  est équivalent à  $G_T$  dans lequel seulement certains noeuds  $u \in S_t$  sont valides (correspondant à des régions déjà segmentées, même partiellement). Pour pouvoir différencier visuellement, nous intégrerons la notion d'activation de noeud du graphe conceptuel initial, comme considéré récemment par [10, Fasquel] (voir fig. 2.3a). Dans le même esprit, nous encadrerons en noir le type recherché. L'ensemble  $S_t \subseteq S$  comprends tous les types de régions qui ont été segmentés jusqu'à  $t - 1$ . À  $t = 0$ , lors de la première séquence, on a  $S_0 = \{0\}$  car toute l'image est implicitement identifiée. Les arêtes de  $G_{T,t}$  demeurent inchangées et correspondent à  $A_T$ .

$\forall u \in S$ ,  $G_{T,t}^{-1}(u)$  renvoie les prédécesseurs valides à  $t$ . Par exemple, dans la figure 2.3a, où seul 1 et 4 ne sont pas valides, les prédécesseurs valides de 5 à  $t$  sont définis par  $G_{T,t}^{-1}(5) = \{2\}$ .

Tout comme  $I$ ,  $I_t = \{X_t(u) \mid u \in S_t\}$  (fig. 2.3b), où  $X_t(u)$  est la région d'une structure  $u$  déjà segmentée ( $u \in S_t \Leftrightarrow X_t(u) \neq \emptyset$ ).

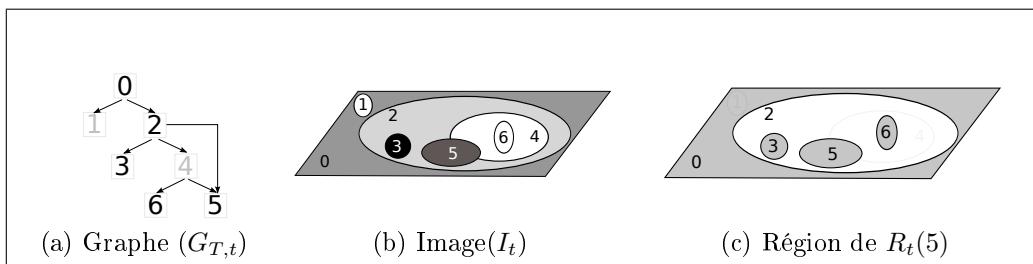


FIGURE 2.3 – Exemple d'information contextuelles à  $t$ . Les noeuds en gris sont dit invalidés, à l'inverse de ceux en noir qui sont valides. En faisant l'analogie avec la figure 2.2, la table (1) et le foie (4) ne sont pas segmentés à cette date  $t$ .



## 2.3 Inférence et topologie : région d'intérêt

On propose de reprendre la définition de la région d'intérêt (Region Of Interest) proposée par [10, Fasquel] qui défini la ROI optimale d'un type  $u \in S$  comme :

$$R_t(u) = \left( \bigcup_{l \in G_{T,t}^{-1}(u)} X_t(\bar{l}) \right) \cup \left( \bigcup_{i \in S_t | u \in G_{T,t}^{-\infty}(i)} X_t(i) \right) \quad (2.1)$$

Le premier membre correspond à l'union des prédecesseurs directs de la cible. La région est réduite autour de la cible par les informations contextuelles des relations, symbolisées par  $G_{T,t}$ . En fait, cette réduction est réalisée par suppression des régions déjà segmentées qui intersectent les régions supposées contenir la cible (au moins partiellement). Ces structures peuvent être du même type que la cible recherchée mais on suppose que deux structures du même type ne s'intersectent pas.

Le second terme vérifie que les régions qui recouvrent partiellement la cible soit conservées dans la ROI. Cela permet par exemple de ne pas supprimer une partie du foie qui sera recouverte par le vaisseau hépatique en supprimant le vaisseau hépatique.

Prenons par exemple, une cible de type 6 (tumeur du foie) :

$$R_t(6) = \left( \bigcup_{l \in G_{T,t}^{-1}(6)} X_t(\bar{l}) \right) \cup \left( \bigcup_{i \in S_t | 6 \in G_{T,t}^{-\infty}(i)} X_t(i) \right) \quad (2.2)$$

De part les informations contextuelles rappelées sur la figure 2.3a, on a  $\{l \in G_{T,t}^{-1}(6)\} = G_{T,t}^{-1}(6) = \{2\}$  et  $\{i \in S_t | 6 \in G_{T,t}^{-\infty}(i)\} = \emptyset$  ce qui nous amène à  $R_t(6) = X_t(2) \setminus (X_t(3) \cup X_t(5) \cup X_t(6))$ . On représente cette région en blanc sur la figure 2.3c.

## 2.4 Inférence et photométrie

Les déductions faites à partir des connaissances disponibles à  $t$  par le moteur d'inférence<sup>1</sup>, portent sur les propriétés photométriques de la région au sein de laquelle vont s'effectuer les traitements.

Ces propriétés photométriques que l'on propose d'inférer, concernent le nombre de classes "photométriques" de la ROI ainsi que leurs relations d'ordres, permettant ainsi d'associer une classe à un noeud du graphe, c'est à dire à une région bien identifiée. Il est à noter que ces déductions dépendent de celles considérées dans la section précédente au sujet de la région d'intérêt optimale.

Pour cette première phase de l'étude, nous faisons l'hypothèse simplificatrice que toutes les régions ont une multiplicité de 1. Cela signifie qu'elles sont dans l'image (aucune n'est optionnelle) et qu'elles sont uniques, il ne peut donc pas y avoir deux tumeurs hépatiques par exemple.

1. Moteur d'inférence : de l'anglais "enference engine" et du verbe "inférer" qui signifie "déduire", c'est un concept de raisonnement déductif à qui on demande des informations et qui déduit des conclusions à partir d'une base de faits et d'une base de connaissances.



### 2.4.1 Nombre de classes

L'objectif est d'isoler un sous-ensemble à priori de types correspondant aux lobes issues d'une région d'intérêt dans l'histogramme d'une image. On présente ci-dessous les étapes majeures qui ont contribué à l'établissement de la formule finale.

Dans un premier temps, nous utilisons la notion de "ROI optimale" présentée dans la section précédente pour déterminer un sous-ensemble nommé  $L_t(u)$ . Ce sous-ensemble est composé de l'ensemble des types non segmentés ( $S \setminus S_t$ ) inclus dans la région d'intérêt d'un type  $u$  et de ses prédécesseurs directs ( $G_{T,t}^{-1}(u)$ ). Formule initiale :

$$L_t(u) = \{i \in S \setminus S_t \mid X(i) \in R_t(u)\} \cup G_{T,t}^{-1}(u) \quad (2.3)$$

Durant l'expérimentation de cette formule, nous nous sommes demandé si l'on pouvait la simplifier du fait que la région  $R_t(u)$  et les successeurs  $G_{T,t}^{-1}(u)$  utilisaient les mêmes informations à priori. En effet la région peut être exprimée par l'ensemble des successeurs des prédécesseurs de  $u : G_T^\infty(G_{T,t}^{-1}(u))$ . La formule précédente devient :

$$L_t(u) = \{i \in S \setminus S_t \mid i \in G_T^\infty(G_{T,t}^{-1}(u))\} \cup G_{T,t}^{-1}(u) \quad (2.4)$$

Elle peut se simplifier en remplaçant le premier membre par l'intersection de l'ensemble non segmenté avec l'ensemble des successeurs des prédécesseurs :

$$L_t(u) = \{(S \setminus S_t) \cap G_T^\infty(G_{T,t}^{-1}(u))\} \cup G_{T,t}^{-1}(u) \quad (2.5)$$

Une forme plus généraliste de  $L_t(u)$  pourrait être, pour un élément  $i$  issu des prédécesseurs de  $u$  ( $i \in G_{T,t}^{-1}(u)$ ), l'union de l'ensemble des successeurs non segmentés dont les prédécesseurs actifs font parti de  $G_{T,t}^{-1}(u)$  et des prédécesseurs de  $u$  eux-mêmes ( $G_{T,t}^{-1}(u)$ ).

$$L_t(u) = \left( \bigcup_{i \in G_{T,t}^{-1}(u)} (S \setminus S_t) \cap G_T^\infty(i) \right) \cup G_{T,t}^{-1}(u) \quad (2.6)$$

Nous avons pu constater lors de tests, une faiblesse de cette formule dans des cas limites comme lorsque l'origine du graphe (0) fait parti des prédécesseurs de  $u$  ou encore quand  $u$  a plusieurs prédécesseurs actifs.

Nous proposons donc la formule suivante qui renvoie l'ensemble des types qui succèdent aux prédécesseurs de  $u$  ( $G_T^\infty(G_{T,t}^{-1}(u))$ ), non actifs, ( $\cap S \setminus S_t$ ), et qui ont au moins un prédécesseur actif direct en commun avec  $u$  ( $G_{T,t}^{-1}(i) \cap G_{T,t}^{-1}(u) \neq \emptyset$ ). A cet ensemble on ajoute l'ensemble des prédécesseurs de  $u$  avec  $G_{T,t}^{-1}(u)$  :

$$L_t(u) = \{i \in (G_T^\infty(G_{T,t}^{-1}(u)) \cap (S \setminus S_t)) \mid (G_{T,t}^{-1}(i) \cap G_{T,t}^{-1}(u) \neq \emptyset)\} \cup G_{T,t}^{-1}(u) \quad (2.7)$$

De cette relation, nous pouvons à présent compter le nombre de lobes  $N_t$  attendus dans l'image à  $t$  par la cardinalité (nombre d'éléments) du sous-ensemble  $L_t(u)$  :  $N_t(u) = |L_t(u)|$ . Rappelons que le nombre de lobes à priori est calculé pour optimiser le paramétrage d'algorithmes de segmentation.



### Exemples applicatifs

Application à une image, qui a les propriétés topologiques  $G_{T,t}$ , dans laquelle on cherche toutes les lobes à priori pour une ROI dans le but de les dénombrer puis de les identifier. On fera un aperçu du résultat graphique sur l'histogramme représentatif d'une image, dans lequel nous ferons apparaître les lobes correspondant aux types segmentés en trait plein. Les lobes en trait discontinu sont considérées comme inconnues. La position des lobes dans l'histogramme et leurs niveaux de gris (en abscisse de l'histogramme) sont représentés selon les informations photométriques à priori issue du graphe  $G_P$  associé. Ce dernier ne sera utilisé qu'à titre d'illustration dans cette section (aucune utilisation de son information).

- Cas 1 : recherche du type 1 sachant que les types 0 et 2 ont été segmentés :

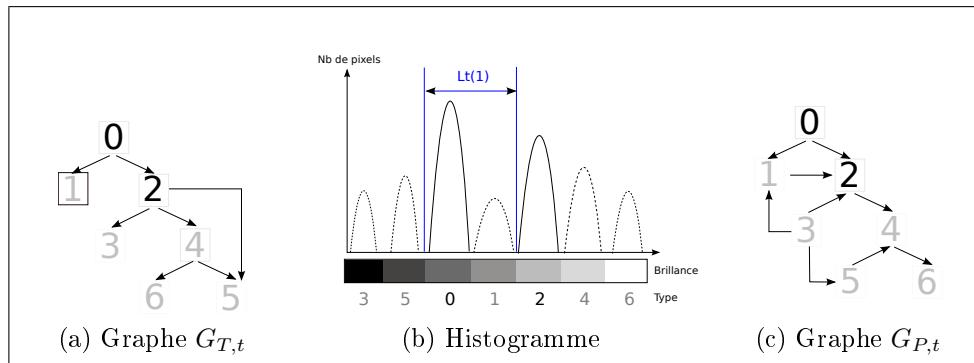


FIGURE 2.4 – Sous-ensemble  $L_t(1)$ .

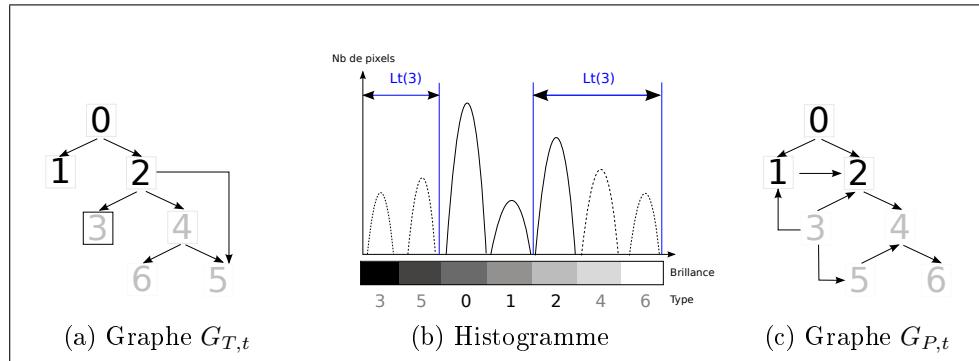
$$\begin{aligned}
 L_t(1) &= \left\{ i \in (G_T^\infty(G_{T,t}^{-1}(1)) \cap (S \setminus S_t)) \mid (G_{T,t}^{-1}(i) \cap G_{T,t}^{-1}(1) \neq \emptyset) \right\} \cup G_{T,t}^{-1}(1) \\
 &= \left\{ i \in (\{1, 2, 3, 4, 6, 5\} \cap \{1, 3, 4, 6, 5\}) \mid (G_{T,t}^{-1}(i) \cap \{0\} \neq \emptyset) \right\} \cup \{0\} \\
 &= \{1\} \cup \{0\}
 \end{aligned} \tag{2.8}$$

Le type 2 étant segmenté, il est exclu du sous-ensemble  $(S \setminus S_t)$  ainsi que les types 3, 4, 5 et 6 car ils n'ont pas de prédécesseurs direct en commun avec ceux de 1 ( $G_{T,t}^{-1}(i) \cap G_{T,t}^{-1}(u) \neq \emptyset$ ). Selon le graphe topologique figure 2.4a. Le deuxième membre  $G_{T,t}^{-1}(1) = \{0\}$  car 1 n'a que 0 comme prédécesseur valide, il en résulte un ensemble de types  $L_t(1) = \{1, 0\}$ . Cet ensemble est représenté sur la figure 2.4b selon  $G_P$  (fig. 2.4c). Sa cardinalité  $N_t(1) = |L_t(1)| = 2$ .

- Cas 2 : recherche du type 3 sachant que les types 0, 1 et 2 ont été segmentés :

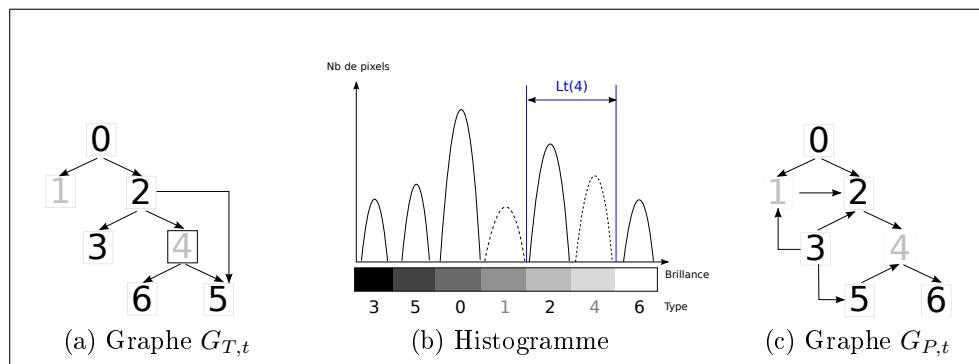
$$\begin{aligned}
 L_t(3) &= \left\{ i \in (G_T^\infty(G_{T,t}^{-1}(3)) \cap (S \setminus S_t)) \mid (G_{T,t}^{-1}(i) \cap G_{T,t}^{-1}(3) \neq \emptyset) \right\} \cup G_{T,t}^{-1}(3) \\
 &= \left\{ i \in (G_T^\infty(\{2\}) \cap \{3, 4, 6, 5\}) \mid (G_{T,t}^{-1}(i) \cap \{2\} \neq \emptyset) \right\} \cup \{2\} \\
 &= \{3, 4, 6, 5\} \cup \{2\}
 \end{aligned} \tag{2.9}$$

Ici l'ensemble des types non segmentés  $S \setminus S_t = \{3, 4, 5, 6\}$  sont conservés car ils ont tous le même prédécesseur (fig. 2.5a). Le deuxième membre  $G_{T,t}^{-1}(3) = \{2\}$  (seul prédécesseur valide


 FIGURE 2.5 – Sous-ensemble  $L_t(3)$ .

de 3), il en résulte un ensemble de types  $L_t(3) = \{3, 4, 6, 5, 2\}$ . Cet ensemble est représenté sur l'histogramme 2.5b. Sa cardinalité  $N_t(3) = |L_t(3)| = 5$ .

- Cas 3 : recherche du type 4 sachant que les types 0, 2, 3, 5 et 6 ont été segmentés :

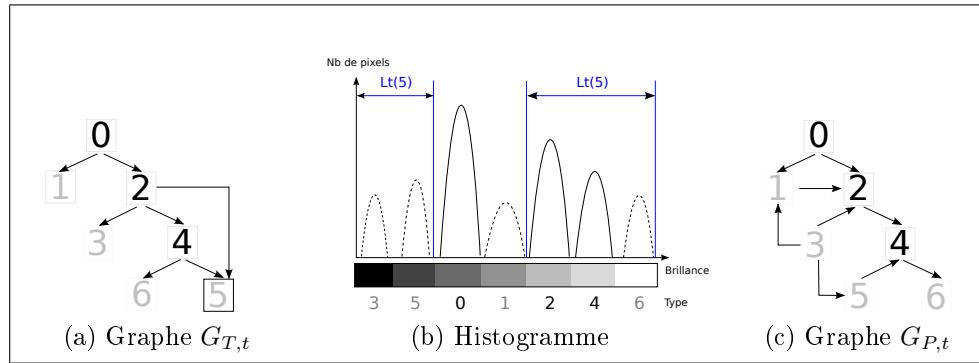

 FIGURE 2.6 – Sous-ensemble  $L_t(4)$ .

$$\begin{aligned}
 L_t(4) &= \left\{ i \in (G_T^\infty(G_{T,t}^{-1}(4)) \cap (S \setminus S_t)) \mid (G_{T,t}^{-1}(i) \cap G_{T,t}^{-1}(4) \neq \emptyset) \right\} \cup G_{T,t}^{-1}(4) \\
 &= \left\{ i \in (\{3, 4, 6, 5\} \cap \{1, 4\}) \mid (G_{T,t}^{-1}(i) \cap \{2\} \neq \emptyset) \right\} \cup \{2\} \\
 &= \{4\} \cup \{2\}
 \end{aligned} \tag{2.10}$$

Parmi l'ensemble des types non segmentés  $S \setminus S_t = \{1, 4\}$ , seul 4 a un prédécesseur identique à  $u$  (fig. 2.6a). Le deuxième membre  $G_{T,t}^{-1}(4) = \{2\}$  vient compléter l'ensemble  $L_t(4) = \{4, 2\}$ . Cet ensemble est représenté sur l'histogramme 2.6b. Sa cardinalité  $N_t(4) = |L_t(4)| = 2$ .

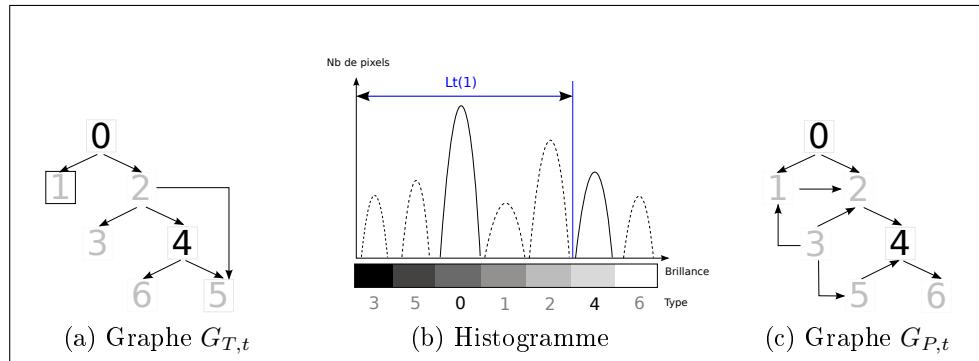
- Cas 4 : recherche du type 5 sachant que les types 0, 2 et 4 ont été segmentés

$$\begin{aligned}
 L_t(5) &= \left\{ i \in (G_T^\infty(G_{T,t}^{-1}(5)) \cap (S \setminus S_t)) \mid (G_{T,t}^{-1}(i) \cap G_{T,t}^{-1}(5) \neq \emptyset) \right\} \cup G_{T,t}^{-1}(5) \\
 &= \left\{ i \in (\{3, 6, 5\} \cap \{1, 3, 5, 6\}) \mid (G_{T,t}^{-1}(i) \cap \{2, 4\} \neq \emptyset) \right\} \cup \{2, 4\} \\
 &= \{3, 6, 5\} \cup \{2, 4\}
 \end{aligned} \tag{2.11}$$


 FIGURE 2.7 – Sous-ensemble  $L_t(5)$ .

Parmi les types non segmentés, le type 1 n'a pas de prédécesseur commun avec ceux de  $u$ , il est donc exclu (fig. 2.7a). Il reste donc 3, 6 et 5 ainsi que les prédécesseurs de  $u$  : 2 et 4 (second membre). L'ensemble trouvé  $L_t(5) = \{3, 6, 5, 2, 4\}$  (fig. 2.7b). Sa cardinalité  $N_t(4) = |L_t(5)| = 5$ .

- Cas 5 : recherche du type 1 sachant que les types 0 et 4 ont été segmentés


 FIGURE 2.8 – Sous-ensemble  $L_t(5)$ .

$$\begin{aligned}
 L_t(1) &= \left\{ i \in (G_T^\infty(G_{T,t}^{-1}(1)) \cap (S \setminus S_t)) \mid (G_{T,t}^{-1}(i) \cap G_{T,t}^{-1}(1) \neq \emptyset) \right\} \cup G_{T,t}^{-1}(1) \\
 &= \left\{ i \in (\{1, 2, 3, 4, 5, 6\} \cap \{1, 2, 3, 6, 5\}) \mid (G_{T,t}^{-1}(i) \cap \{0\} \neq \emptyset) \right\} \cup \{0\} \\
 &= \{1, 2, 3, 5\} \cup \{0\}
 \end{aligned} \tag{2.12}$$

Ici on teste le cas où les types n'ont pas été segmentés suivant l'ordre topologique. La formule reste robuste car on obtient bien l'ensemble des prédécesseurs de 1 avec leurs successeurs non segmentés à l'exception de 6 puisque il a pour prédécesseur  $\{4\} \neq \{0\} = G_{T,t}^{-1}(1)$ .



### 2.4.2 Identification des lobes

Nous identifions les lobes (correspondant aux classes de l'image) présentes dans l'image pour pouvoir optimiser le fenêtrage de la structure recherchée. L'identification consiste en l'ordonnancement des lobes de l'ensemble  $L_t$  en fonction de leur intensité lumineuse. Dans cette étude, et sous l'hypothèse d'une distribution des intensités selon un loi normale, “plus sombre”, se traduira par la moyenne (de la gaussienne) des intensités de  $i$  est inférieure à la moyenne des intensités de  $j$ . On s'appuie sur les relations photométriques inter-types que l'on représente par un graphe (voir fig. 2.9a) dont des arcs orientés signifient “plus sombre que”. On utilise ensuite l'opérateur `ord` qui comparera les relations photométriques inter-type jusqu'à l'obtention d'une suite de types ordonnés par intensité moyenne croissante. On exprime cette opération par :

$$O_t(u) = \text{ord}\{L_t(u)\} = \{L_{t,i}(u) \mid i \in \{0, \dots, N_t - 1\}\} \quad (2.13)$$

Cet ensemble est ordonné, ce qui signifie que,  $\forall (i, j) \in \{0, \dots, N_t - 1\}^2 \mid (L_{t,i}(u), L_{t,j}(u)) \in (O_t(u), L_{t,i}(u) < L_{t,j}(u))$ <sup>2</sup> :

- En terme d'image : la région  $X(i)$  est plus sombre que la région  $X(j)$
- En terme de graphe : le noeud  $i$  est prédécesseur de  $j$  dans le graphe  $G_P \Rightarrow i \in G_{P,t}^{-\infty}(j)$

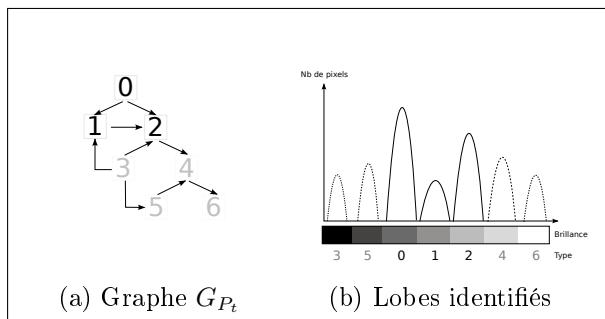


FIGURE 2.9 – Exemple de représentation des informations photométriques ( $G_{P,t}$ ) correspondant au cas n°2 énoncé plus haut.

Appliqué au cas n°2,  $O_t(3)$  compare la relation photométrique entre les types de l'ensemble  $L_t(3) = \{2, 3, 4, 5, 6\}$  deux à deux, c.a.d. chaque type  $i \in L_t(3)$  va être comparé à un autre type  $j \in L_t(3)$  itérativement.

Selon 2.9a, 2 est plus clair que 3 qui est plus sombre que 5 et ainsi de suite  $\Rightarrow O_t(3) = \{3, 5, 2, 4, 6\}$ . Le premier lobe de l'histogramme 2.9b est donc identifié comme étant de type 3, le second de type 5 et ainsi de suite sachant que 0 et 1 sont exclus de  $L_t(3)$ .

---

2. La relation  $\in O, L < L$  ne me semble pas claire, est-ce vraiment la représentation standard pour un ensemble ordonné et sont opérateur ? Ne doit-on pas plutôt utiliser des accolades quand on parle d'ensemble ?



## 2.5 Discussion : limites et perspectives

Dans la formulation dédiée à la photométrie (section 2.4), nous avons considéré des régions avec une multiplicité de 1. Cette hypothèse simplificatrice signifie que nous avons ignoré les situations suivantes :

- le caractère optionnel d'une région (e.g. une tumeur peut être absente bien que représentée dans le graphe) ;
- le caractère multiple d'une région : ceci peut notamment concerner le cas de tumeurs multiples, chacune d'elles étant segmentée à une étape différente du processus d'analyse ;
- le cas où une région  $A$  contient des sous-régions dont l'union occupe toute la région  $A$  : il n'y alors aucune classe (lobe de l'histogramme) qui correspond spécifiquement à la région  $A$ .

Contrairement au cas de la ROI [10, Fasquel], cet aspect a un impact sur les déductions faites par le moteur d'inférence comme le nombre de classes. Ce choix est justifié par le fait que la formalisation proposée apparaît, comme constaté dans les sections précédentes, relativement complexe, malgré cette hypothèse simplificatrice. Ceci justifie donc de débuter l'étude dans un cas simple même si l'hypothèse simplificatrice peut s'avérer très limitante d'un point de vue applicatif (e.g. cas précédemment cité des tumeurs).

L'élimination de cette hypothèse nécessite de poursuivre l'étude, ce qui aurait probablement pour conséquence de modifier le formalisme présenté, notamment concernant la détermination du nombre de classe qui conduirait non plus à une valeur exacte mais probablement à un intervalle (e.g. selon qu'une tumeur est présente ou non, le nombre de classe peut varier entre un minimum et un maximum).

Nous avons fait le choix d'évaluer cette première phase de l'étude en priorité afin d'en discuter des bénéfices, plutôt que d'étendre davantage le formalisme. Le bilan de cette partie est que la formalisation n'est pas triviale, contrairement à ce que l'on pourrait intuitivement penser en première approche, et qu'une étude des bénéfices semble pertinente avant de légitimer un effort de formalisation supplémentaire.

Néanmoins, avant de détailler les études relatives à cette évaluation, nous présentons succinctement quelques pistes qui pourraient être envisagées dans le cas d'une multiplicité supérieure à 1. Le caractère optionnel (multiplicité 0) n'ayant pas été abordé.

Une piste envisageable repose sur l'ajout d'un attribut (nous le noterons  $M$ ) à chaque noeud du graphe, spécifiant la multiplicité potentielle d'une région. Une limitation de cette approche concerne l'élément quantitatif introduit dans la représentation des connaissances, sachant que nous privilégions une représentation des connaissances non quantitative dans la méthode proposée. Dans ce contexte, nous ferons l'hypothèse que les différentes régions d'une même classe ( $M > 1$ ) présentent les mêmes propriétés photométriques.

# 3 Évaluation

L'objectif de cette partie est d'évaluer les bénéfices des connaissances à priori présentées dans le chapitre 2 (la région d'intérêt, le nombre de classes et les relations d'ordre). Elles sont déduites des représentations conceptuelles des connaissances topologiques et photométriques, dans le cas d'une analyse séquentielle.

Intuitivement, l'information topologique permet :

- a) d'éliminer les données polluantes : amélioration du pourcentage de données utiles ;
- b) réduire le volume des données à traiter : complexité et temps de calcul réduits.

L'information photométrique permet de :

- c) connaître le nombre et l'ordre des classes à priori : paramétrage des algorithmes de segmentation ;
- d) initialiser les algorithmes de segmentation au plus proche des paramètres des classes attendues (moyenne, intervalle) : moins d'itérations lors de la segmentation.

A partir de ces considérations intuitives, nous proposons d'effectuer un certain nombre de tests permettant d'illustrer quantitativement les bénéfices. Il s'agit d'un exercice délicat, comparativement aux procédures classiques d'évaluation de la performance de classification d'un algorithme de segmentation (e.g. mesure objective du taux de pixel correctement classés). En effet, dans notre contexte, cette évaluation ne dépend pas seulement de la nature des données, mais également de l'algorithme et de la procédure itérative d'analyse (la région d'intérêt varie à chaque itération). Par conséquent, ces mesures quantitatives reflètent probablement moins objectivement les bénéfices de notre approche que dans le cas d'un algorithme particulier.

Notre objectif prioritaire est de montrer des cas dans lesquels notre approche facilite le traitement, afin d'alimenter notre argumentaire, et ainsi, de discuter des affirmations précédentes, dans des cas concrets. Cette démarche sera poursuivie dans un cadre plus applicatif dans le chapitre suivant dédié à une application médicale.

Après une courte présentation de l'algorithme utilisé pour réaliser cette évaluation, nous allons traiter chacun des points cités précédemment (a, b, c, d).

## 3.1 Algorithme considéré

Nous avons choisi d'utiliser l'algorithme des *K-Means* car il est largement répandu pour les raisons évoquées dans [17, Ranjan] “*the simplicity and computational speed of the K-means algorithm ... has made it a popular choice.*”. Cet algorithme nécessite néanmoins des paramètres d'initialisations pour calculer une segmentation pertinente [17, Ranjan] “*the algorithm needs initializing values which greatly influence its terminating optimal solution ... good initialization is crucial for finding globally optimal partitionings*”.

L'algorithme *K-Means* est une méthode dont le but est de diviser  $n$  observations  $X$  en  $k$  partitions (clusters)  $V = \{V_1, V_2, \dots, V_k\}$  afin de minimiser la somme des carrés à la moyenne à l'intérieur de chaque partition (eq. 3.1).



$$\arg \min \sum_{j=1}^k \sum_{n \in V_j} |X_n - \mu_j|^2 \quad (3.1)$$

Les paramètres sont : le nombre de partitions  $k$  et leurs moyennes respectives. Nous déterminerons  $k$  par les connaissances contextuelles à priori. Pour l'initialisation des moyennes, on peut utiliser des moyens automatiques comme le tirage aléatoire de valeurs, l'algorithme *K-Means++*[1, Arthur2007] ou bien manuellement.

Le contexte d'utilisation de cet algorithme s'apparente à de la segmentation d'images par analyse d'histogramme (analyse de la distribution des intensités). Il s'agit d'une approche couramment considérée en traitement d'images, l'enjeu étant la détermination robuste des seuils discriminant les différentes régions d'une image ([6, Coudray], [2, Bhattacharyya], [5, Cheng], [7, Cuevas]). Le lecteur pourra également se référer à l'état de l'art de [23, Zhang] sur ces méthodes.

## 3.2 Élimination des données polluantes

### Efficacité de segmentation

Ici nous allons illustrer l'avantage des masques pour l'élimination des données polluantes de l'image. Ces données polluantes sont souvent caractérisées par des régions de l'image situées en dehors de la ROI (topologiquement) mais avec des intensités proches de celles se trouvant au sein de la ROI. Ces intensités sont donc confondues dans l'histogramme de l'image et biaissent la segmentation. En comparant les deux histogrammes, on voit clairement que les intensités de la région C se mélangent à celles des régions B et D (fig. 3.1c et 3.1f).

Afin de discuter de cet aspect, nous allons considérer le cas de la segmentation de la région D, en considérant que B ait été segmenté ou non :

- Cas B segmenté : la segmentation de D se fait au sein de la région B (fig. 3.1d) conduisant à un histogramme comprenant des lobes bien distincts (fig. 3.1f). L'application de *K-Means* initialisé avec *K-means++* permet une segmentation quasiment sans erreur de D (fig. 3.1e). Ce résultat aurait pu être vérifié avec un autre algorithme de segmentation. Le nombre de faux positifs<sup>1</sup> et faux négatifs<sup>2</sup> sont très faibles, respectivement 2 et 0.
- Cas B non segmenté : la segmentation de D se fait en considérant toute l'image (fig. 3.1a). L'application de *K-Means* dans les mêmes conditions que précédemment conduit à un seuil erroné (i.e. le seuil inférieur sera trop élevé, correspondant à la vallée entre les lobes C et D sur l'histogramme fig. 3.1c et non au minimum réel de D). Davantage de points sont classés comme n'appartenant pas à D : le taux de faux négatifs augmente grandement (761 pixels). Inversement, un certain nombre de points de C sont, par erreur, associés à la région D : le taux de faux positifs augmente également (352 pixels).

Il est à noter qu'afin de pouvoir comparer les deux approches, il semble plus pertinent de focaliser la comparaison sur les points de D qui ne sont pas associés à D après segmentation alors

1. Faux positifs (FP) : points considérés comme appartenant à la région cible (e.g. D) à tort.

2. Faux négatifs (FN) : points considérés comme n'appartenant pas à la région cible (e.g. D) à tort.

### 3.2. ÉLIMINATION DES DONNÉES POLLUANTES

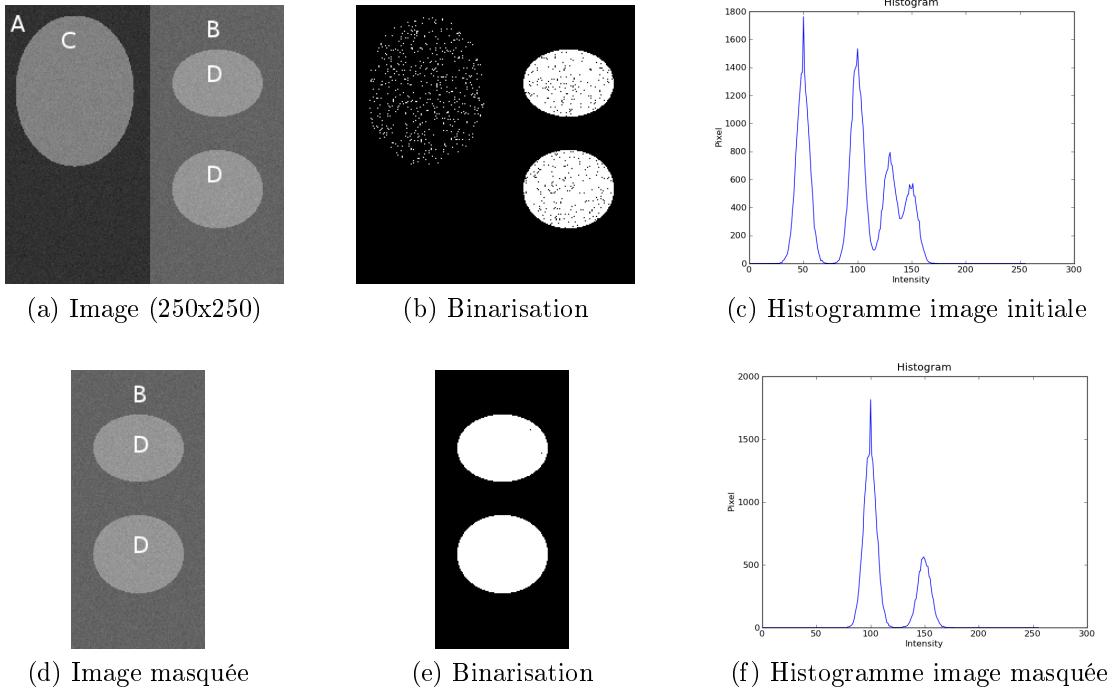


FIGURE 3.1 – Images et histogrammes associés

qu'ils devraient l'être (faux négatifs) : on ignore alors les performances de classification en dehors de D, ceci dépendant de la ROI au sein de laquelle les traitements sont effectués (très variable en fonction des structures externes à D). Par conséquent, le seul critère significatif à notre sens est celui faisant intervenir les vrais positifs et les faux négatifs : la sensibilité<sup>3</sup>. La spécificité<sup>4</sup> ne faisant intervenir que les vrai négatifs et les faux positifs.

Région D	C non masqué		C masqué	
	Vrai	Faux	Vrai	Faux
Positif	8018	352	8368	2
Négatif	53369	761	21630	0
Sensibilité	91.33%		100%	
Spécificité	99.35%		99.99%	

TABLE 3.1 – Classement des pixels

### Temps de calcul

Illustrons le fait que, pour un même volume de données à traiter, que le nombre moyen d'itération des algorithmes de segmentation tel que *K-Means* dépend du nombre de classes de l'image.

3. Sensibilité : proportion de points positifs qui ont été classés positifs :  $VP / (VP + FN)$ , VP désignant les vrai positifs (points considérés comme appartenant à la région cible à raison).

4. Spécificité : Proportion de points négatifs qui ont été classés négatifs :  $VN / (VN + FP)$ , VN désignant les vrais négatifs (points considérés comme n'appartenant pas à la région cible à raison).



Comparons les trois images synthétiques ci-dessous (fig. 3.2a, 3.2b et 3.2c) et calculons le nombre d’itérations moyen, pour 50 essais, que met l’algorithme pour converger vers leurs nombre de classes respectifs.

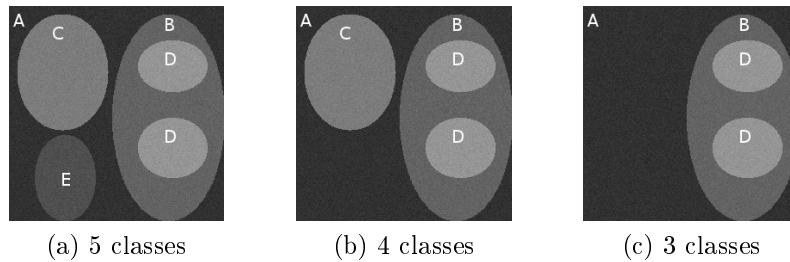


FIGURE 3.2 – Images synthétiques ayant un nombre de classe différent.

Il apparaît que, indépendamment du volume de données, le nombre de classes de l’image influence le temps de traitement (voir tableau 3.2). Ceci souligne donc un second intérêt d’éliminer les données polluantes car elles peuvent augmenter le nombre de classes et donc ralentir l’analyse. Ceci contribue également à montrer l’intérêt de réduire les analyses à une région d’intérêt, en ignorant les données polluantes, et ce même si elles ne diminuent pas la performance de la segmentation (e.g. données polluantes bien distinctes, en terme de lobe sur l’histogramme, des lobes d’intérêt). Il est à noter que cette observation dépend fortement de la nature de l’algorithme de segmentation choisi car certains ne dépendent pas du nombre de classes.

	Image 5 classes	Image 4 classes	Image 3 classes
Nombre d’itérations	6.34	3.52	1.2

TABLE 3.2 – Nombre d’itérations moyen pour 50 essais par image

### 3.3 Réduction de la quantité de données à traiter

Le temps de calcul est directement lié au nombre de données à traiter, quantifions ce gain à partir du tableau (tab. 3.1, région D). L’image (fig. 3.1a) contient 250x250 pixels, le temps moyen de convergence avec *K-Means* (10 itérations) est de 1,2 secondes sans masque et 0,8 secondes avec masque (fig. 3.1a de 130x250 pixels). On considérera un gain d’environ de **30%**.

Les masques sont d’autant plus bénéfiques pour les images médicales puisque qu’elles contiennent beaucoup plus de données (de l’ordre de 512x512xN pixels sans masque). Prenons comme exemple une image, constituée du foie, de tumeurs et de la rate, dans laquelle on recherche les tumeurs du foie (en rouge sur l’histogramme 3.3), on sait qu’une tumeur du foie n’est pas, topologiquement, dans la rate (en vert sur l’histogramme 3.3b), on peut donc la masquer (voir l’histogramme 3.3c). Les temps de calcul moyens pour trois (foie + tumeur + rate) puis deux (foie + tumeur) classes avec *K-Means* (10 itérations) sont respectivement de 3,2 et 2,3 secondes. Soit un gain de **28%**. Ces mesures ont été réalisées avec un processeur Intel Core 2 Duo à 2.66Ghz.

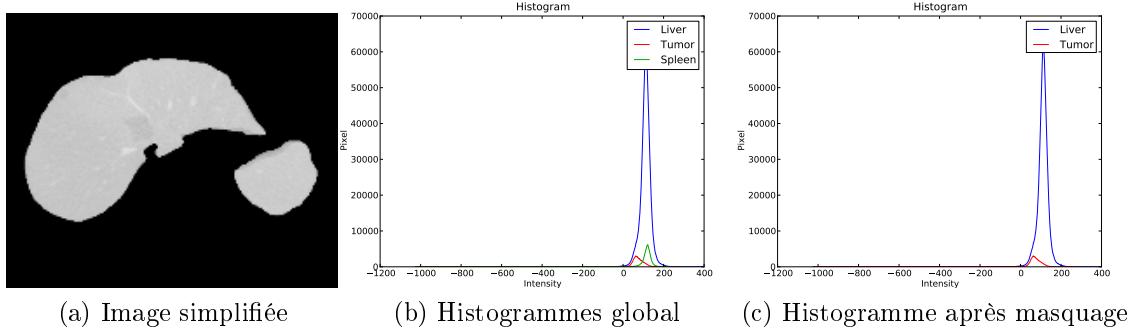


FIGURE 3.3 – Images et histogrammes associés

## 3.4 Connaissance du nombre de classe à priori

La connaissance du nombre à priori de classe dans l'image est un paramètre essentiel à certains algorithmes de segmentation comme *K-Means* puisque c'est le nombre de classe qu'ils créent. Comme récemment souligné [17, Ranjan], ceci est un point critique encore non résolu. Pour illustrer et discuter du bénéfice de la connaissance à priori du nombre de classes, nous allons considérer la méthode proposée par [18, Ray]. Il s'agit d'un choix arbitraire, sachant que d'autres méthodes auraient pu être utilisées (ceci pourrait faire l'objet d'une étude complémentaire). Cet algorithme d'estimation du nombre de classes est basé sur un critère de validité faisant intervenir le rapport entre les variances des classes et la distance minimum entre les classes obtenues par *K-Means*. Cette mesure est réalisée pour un certain nombre de classes. Le nombre de classes optimal correspond au critère de validité minimum entre le premier maximum et la dernière valeur (correspondant au nombre maximum de classes). Une limitation est que cette méthode ne peut s'appliquer qu'à des données contenant au moins 4 classes.

En considérant cette approche automatique, nous allons discuter ci-après de l'intérêt de la connaissance à priori entre d'efficacité et de temps de calcul.

### Efficacité : les limites d'une détermination automatique

Considérons une image synthétique à 8 classes (fig. 3.4a), le critère proposé dans [18, Ray] permet d'automatiquement déterminer le nombre de classes, sans requérir de connaissance à priori supplémentaire : la courbe passe par un minimum à 8 correspondants au nombre de classes de l'image. On obtient donc une estimation correcte du nombre de classes.

Néanmoins, comme illustré par la figure 3.4b, lorsque les classes apparaissent moins distinctes (voir "data set" fig. 3.4b), on constate que l'estimation automatique échoue (la courbe indique une minimum pour 4 classes au lieu de 8), tandis que la connaissance à priori permet d'obtenir un résultat plus juste (voir la coloration des points dans la partie inférieure de 3.4b). Ceci peut être vu comme un résultat assez intuitif, c'est pourquoi il est rapporté afin d'illustrer uniquement le fait qu'il peut être plus efficace de disposer de connaissance a priori que de disposer d'un algorithme non supervisé qui viendrait compenser l'absence de connaissance a priori.

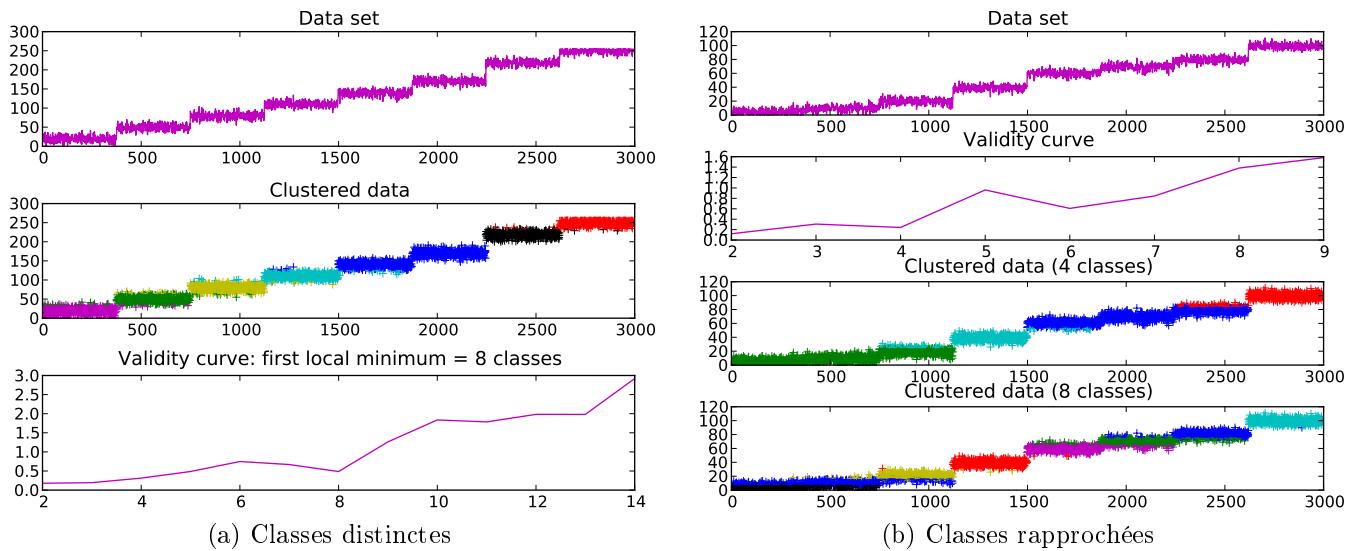


FIGURE 3.4 – Mise en échec de l'algorithme de validation

## Temps de calcul : le coût d'une détermination automatique

Prenons l'exemple d'une image dont on ne connaît pas le nombre à priori de classe, on recherche entre 2 et  $N_{max}$  classes (ici  $N_{max} = 14$ ). Il faudra environ 1 minute pour appliquer  $K$ -Means de 2 à 14 classes et déterminer automatiquement qu'il y a 8 classes dans l'image. De part le moteur d'inférences, nous disposons directement du nombre de classes a priori, permettant ainsi d'éviter de faire des calculs inutiles ce qui s'avèrent être non négligeable dans cet exemple, puisque l'application direct de  $K$ -Means à 8 classes ne prend que 5 secondes. La détermination automatique est, dans ce cas, est **12 fois plus lente**. Cela semble évident puisque qu'il y a douze cas à tester.

## 3.5 Relations photométriques et initialisation des centroïdes

Nous pouvons déterminer à partir des informations photométriques la position relative des classes dans l'histogramme (e.g. plus claire à droite, plus foncé à gauche). Cette information est particulièrement intéressante si l'on cherche une ou plusieurs classes qui sont entre deux autres segmentées (dont on connaît les centroïde) ou entre une segmentée et un extremum d'intensité. Malgré que cet aspect soit très dépendant du contexte, il est néanmoins non négligeable dans certains cas limites comme celui illustré ci-après.

La connaissance à priori du centroïde (proche de la notion de moyenne) de chaque classe de point est un paramètre que peut intégrer l'algorithme  $K$ -Means, nous allons donc quantifier son apport. Prenons l'exemple d'une image à cinq classes (fig. 3.5a) dont ont suppose que les classes A et D ont été segmentées et masquées (centroïdes de 25 et 150 en vert fig. 3.5c). On peut estimer une répartition à priori des centroïdes des classes B, C et E sachant que deux d'entre elles ont une intensité moyenne comprises entre celle de A et D, qu'une troisième est plus grande que D et que les intensités de l'image sont comprises entre 0 et 255 (image 8 bits). Dans cet exemple, l'estimation initiale des centroides relatifs à B et C sont répartis de manière équilibrée entre les intensités moyennes mesurées des classes A et E. L'estimation initiale du centroïde relatif à E correspond

### 3.5. RELATIONS PHOTOMÉTRIQUES ET INITIALISATION DES CENTROÏDES



à l'intensité moyenne entre celle de D et l'intensité maximale de l'image (voir les positions des centroïdes en vert sur la fig. 3.5c).

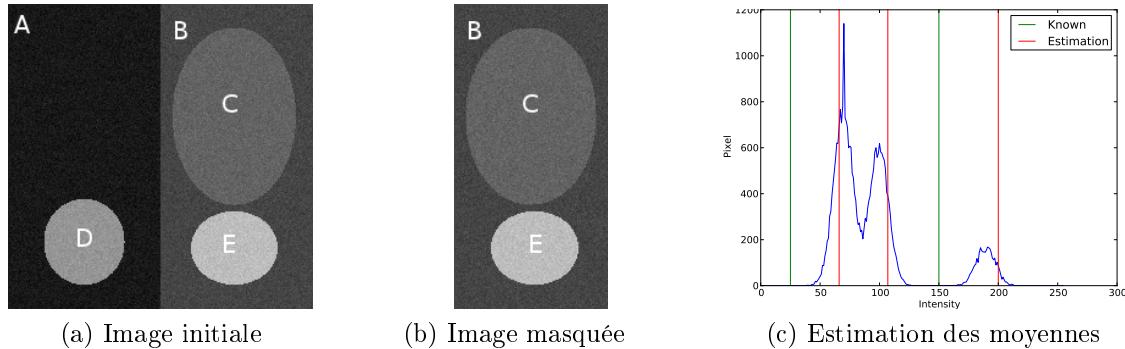


FIGURE 3.5 – Images et histogrammes associés

Le tableau suivant montre les résultats obtenus avec *K-Means* initialisé avec des moyennes aléatoires puis calculés à partir des connaissances à priori dans le cas où la ROI correspond aux régions B, C et E (fig. 3.5b) :

$\sum$ variances	1	2	3	4	5	6	8	9
Aléatoire	168131	168009	743240	168405	168131	168118	743240	743174
Prédéfinie	168131	168131	168131	168131	168131	168131	168131	168131

TABLE 3.3 – Sommes des variances

La somme des variances (inerties) témoigne de la dispersion des valeurs par rapport à la moyenne, on constate qu'elle est stationnaire pour une initialisation avec des moyennes prédéfinies alors qu'elle fluctue dans le cas de l'initialisation aléatoires. Les valeurs sont très dépendantes du contexte mais la fluctuation pourrait être vérifiée dans d'autre cas. Les figures ci-après montrent quelques résultats de classification pour trois différentes inerties. Elles illustrent la relation entre une inertie élevée et la répartition des points entre les classes.

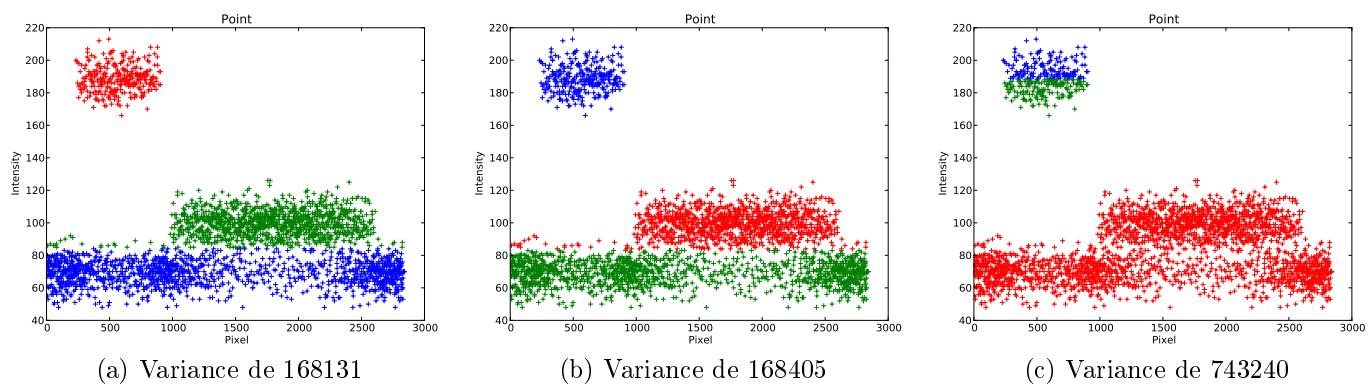


FIGURE 3.6 – Partitionnement et inertie : la figure (c) montre une classification inacceptable.

# 4 Application

## 4.1 Introduction

En médecine, il existe beaucoup de modalités d'imagerie, le choix de la modalité utilisée étant notamment fonction de la région anatomique étudiée et de l'acte diagnostic visé.

Nous limiterons l'étude à des images de la région de l'abdomen issues de scanners à rayon X, communément appelées images CT<sup>1</sup>. Ces scanners délivrent des images dont les intensités s'échelonnent souvent de -1024 à des valeurs supérieures à 1000 unité Hounsfield ([19, Rossner], [22, zhu], [3, Brown], [6, Coudray], [13, Bengoetxea]), cette dynamique photométrique est bien trop étendue pour l'œil.

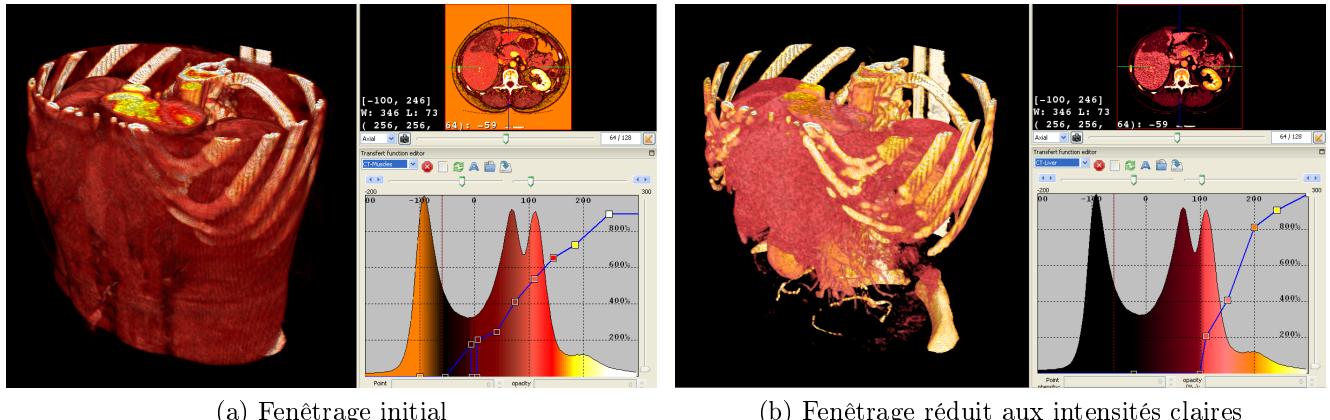


FIGURE 4.1 – Influence du fenêtrage sur le rendu visuel.

Afin de distinguer aisément les différentes structures anatomiques et pathologiques<sup>2</sup>, il convient de visualiser qu'une partie de la dynamique, ceci étant souvent associé au terme de fenêtrage. Voir l'exemple applicatif figure 4.1a et 4.1b où on fait varier le fenêtrage (courbe bleu sur l'histogramme) de l'image [21, Gonzalez, Pratt]. Un fenêtrage approprié peut faciliter la segmentation dans le cas d'une procédure interactive de segmentation et d'identification de structures anatomiques et/ou pathologiques où l'utilisateur intervient pour visualiser et ajuster le déroulement du traitement d'une image. Il lui est alors nécessaire de bien voir la structure à segmenter d'où l'intérêt d'intégrer la visualisation au processus d'analyse de l'image.

Une méthode triviale consisterait à disposer d'un dictionnaire d'intervalles photométriques pour les différentes structures types (e.g. : foie, vaisseaux, os). La visualisation serait alors contrôlée par des constantes (quantitatives) et pourrait présenter un manque de robustesse par rapport à une méthode de détermination automatique, fondée sur des mesures effectuées sur l'image en cours

1. Computed Tomography (CT) : est une technique d'imagerie médicale qui consiste à mesurer l'absorption des rayons X par les tissus puis, par traitement informatique, à numériser et enfin reconstruire des images 2D ou 3D des structures anatomiques (<http://fr.wikipedia.org/wiki/Tomodensitomtrie>)

2. La pathologie est l'étude des maladies et de leurs causes. Le terme peut être employé comme un nom pour désigner une anomalie dans un corps.



d'étude : le fenêtrage devient alors spécifique au patient, et prend en compte ses particularités (e.g. : densité des tissus variable d'un patient à l'autre [3, Brown]).

On se placera dans le contexte d'une analyse séquentielle où le fenêtrage sera déterminé automatiquement à partir des structures déjà segmentées, de la structure recherchée (cible) et d'une analyse d'histogramme paramétrée par des inférences (déductions) sur les connaissances conceptuelles. Idéalement, il serait utile de pouvoir automatiquement déterminer le fenêtrage correspondant à la structure anatomique ou pathologique d'intérêt, pour la présenter de la manière la plus explicite aux yeux d'un professionnel. Les travaux présentés ci-après constituent des essais préliminaires, et aucune évaluation quantitative n'a été réalisée dans ce rapport. Il s'agit dans un premier temps d'illustrer l'application de notre approche à des données réelles. Les commentaires concerteront des remarques subjectives (et non objectives) relatives à la qualité du rendu visuel.

## 4.2 Cadre expérimental

### 4.2.1 Données

Nous utiliserons une image issue d'une base de données d'images CT issue du site de l'IRCAD<sup>3</sup>. Cette base de donnée contient des lots d'images (entre 100 et 200 images par patient) et certain masques (fig. 4.2b à 4.2e) de structures anatomiques et pathologiques. Ces masques ont été obtenus par des algorithmes de segmentations spécifiques à chaque structure. Ces images sont au format DICOM [4, 15] et contiennent 512x512 pixels chacune (fig. 4.2a).

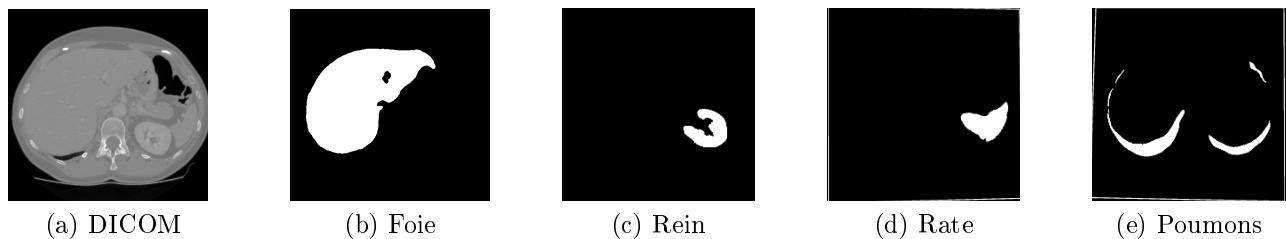


FIGURE 4.2 – Données expérimentales : données brutes (a) et masques (b, c, d, e).

Nous travaillerons sur une image médicale (fig. 4.3a) comportant 9 classes que nous définissons comme étant de type : acquisition (0), patient (1), os (2), poumons (3), rein (4), rate(5), foie (6), tumeur hépatique (7) et réseau vasculaire (8). Nous nous appuierons sur leurs connaissances à priori topologiques (fig. 4.3b) et photométriques (fig. 4.3c).

Pour ces premières expériences, nous considérons seulement les régions pour lesquelles nous disposons d'un masque (créé à partir de leurs segmentation). Ceci permet de nous affranchir en partie du besoin d'une représentation (au niveau du graphe) complète de toutes les structures composant l'abdomen. Ceci a pour conséquence de considérer que l'image initiale, avant toute segmentation, ne contient pas d'estomac par exemple. Ce que nous considérons comme acquisition (0) est l'ensemble de l'image, le patient (1) étant simplement l'union des régions constituant les différentes structures citées précédemment. Il est à noter tout de même que certaines structures

<sup>3</sup>. IRCAD : Institut de Recherche contre les Cancers de l'Appareil Digestif, emplacement de la base de données d'images : <http://www.ircad.fr/softwares/3Dircadb/3Dircadb1/>

## 4.2. CADRE EXPÉRIMENTAL



sont elles-mêmes composées de structures (e.g. réseaux vasculaire des poumons) qui ne sont ni segmentées (i.e. pas de masque) ni documentées (i.e. pas de noeud dédié dans la représentation des connaissances) : ceci constitue donc la limite de la simplification que nous opérons en retirant un certain nombre de structures telles que l'estomac et le colon.

Une conséquence de la simplification des données est que le type patient (1) est l'union des structures qu'il contient (successeurs), et ne présente donc pas de données qui lui sont propres. Il s'agit d'une situation non considérée dans le formalisme proposé dans ce travail, on ne peut donc pas tester n'importe quel scénario.

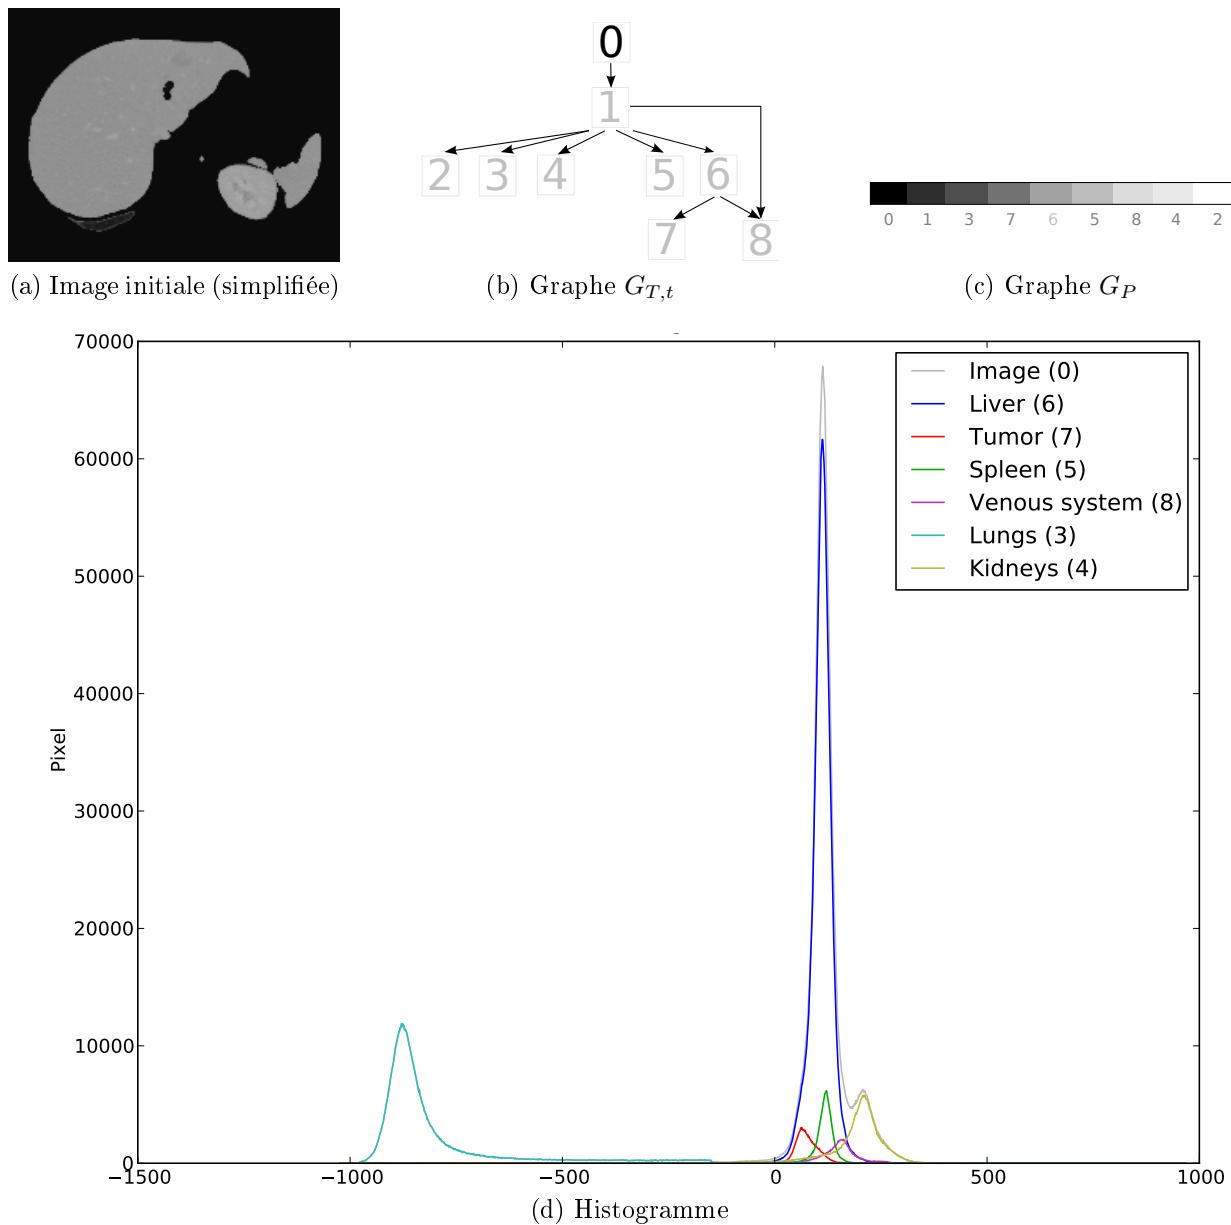


FIGURE 4.3 – Données expérimentales (simplifiées), connaissances à priori et histogramme



### 4.2.2 Mode opératoire

Pour chaque scénario, nous allons considérer qu'une procédure d'analyse particulière a été exécutée, conduisant à la segmentation d'un certain nombre de structures. Il est à noter que nous ignorons la procédure ayant permis de segmenter chacune des structures, ceci étant hors du champ de notre étude. Néanmoins, nous considérerons une cible particulière qui concernera soit les vaisseaux hépatiques, soit les tumeurs du foie ; l'objectif étant d'utiliser notre approche en combinant inférences et algorithme de segmentation (*K-Means*) afin de déterminer le fenêtrage à considérer pour optimiser le rendu volumique.

Nous comparerons nos résultats à la vérité terrain qui est caractérisée par la distribution des points de chaque structure cible représentée dans histogrammes 4.4. Le tableau 4.1 présente la moyenne  $\mu$ , l'écart type  $\sigma$  et l'intervalle à  $\pm 3\sigma$  (contenant 99.99966% des valeurs).

Nom	$\mu$	$\sigma$	$\mu - \sigma$	$\mu + \sigma$	$\mu - 3\sigma$	$\mu + 3\sigma$
Tumeurs	76	25	51	101	1	151
Foie	115	20	95	135	55	175
Vaisseaux hépatiques	152	45	107	197	17	287

TABLE 4.1 – Résultats des estimations

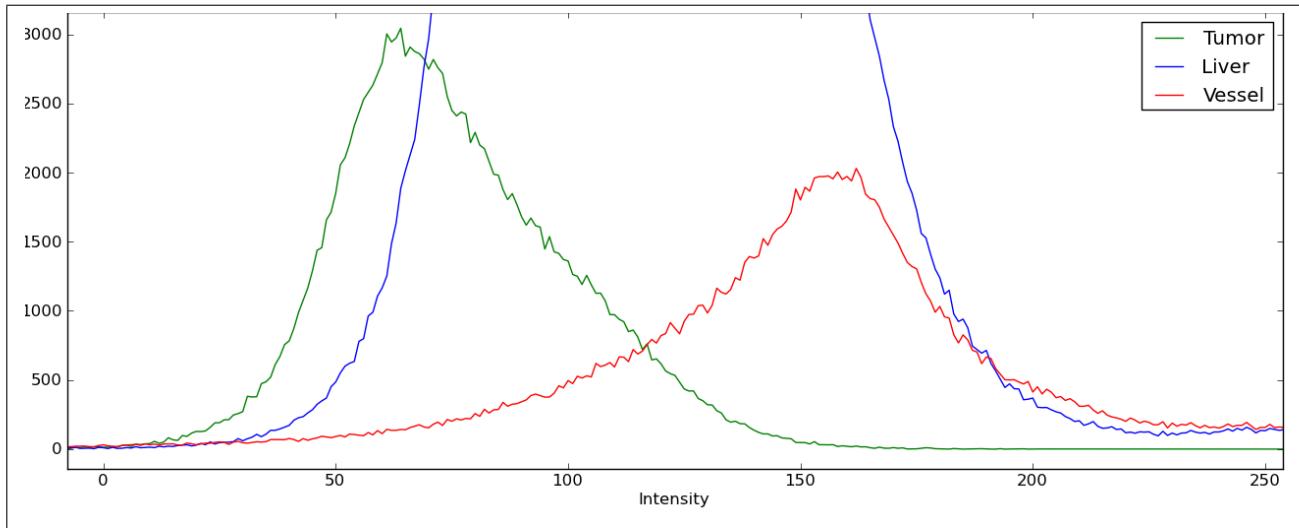


FIGURE 4.4 – Histogrammes des distributions

### 4.2.3 Fenêtrage

Le fenêtrage utilisé pour configurer le rendu volumique d'une structure cible sera déterminé en fonction de l'intervalle d'intensité fourni par *K-Means* de manière à maximiser le nombre de pixels visibles et à minimiser les autres. Pour ces premières expériences nous choisirons de calculer deux fonctions de transfert triangulaire bornée par cet intervalle. Nous comparerons ces résultats à une fonction de transfert triangulaire bornée par intervalle de référence  $[-\sigma, +\sigma]$  puis ajustée manuellement.



### 4.3 Scénario 1 : les tumeurs hépatiques

On se place dans un cas où l'on veut visualiser les tumeurs hépatiques (7). La procédure d'analyse pourrait être que le patient (1) soit tout d'abord segmenté (conduisant ainsi au graphe fig. 4.5a) puis le foie (fig. 4.5b). On peut maintenant s'intéresser au fenêtrage de (7) à partir de l'image obtenue après l'application du masque du foie (fig. 4.5c). On peut voir sur l'histogramme (fig. 4.5d) les données avant (courbe grise) et après (courbe bleu) l'application du masque.

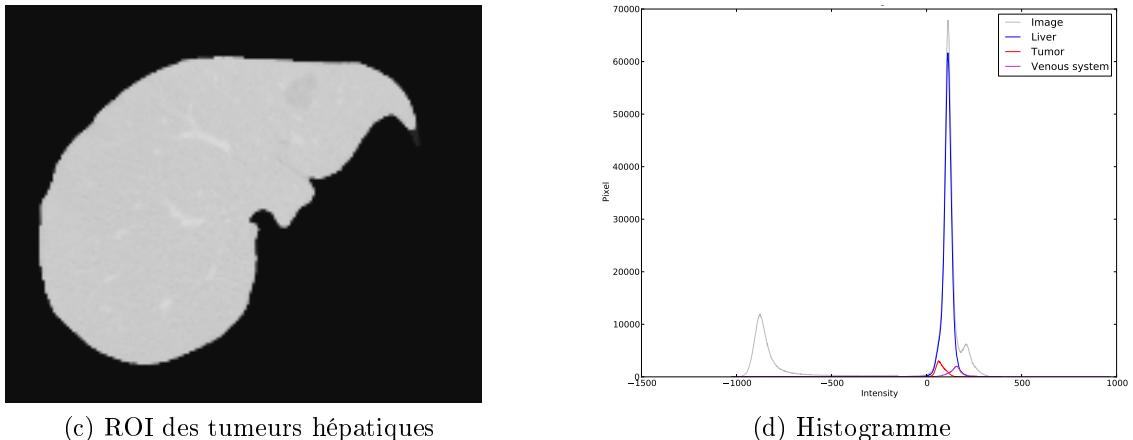
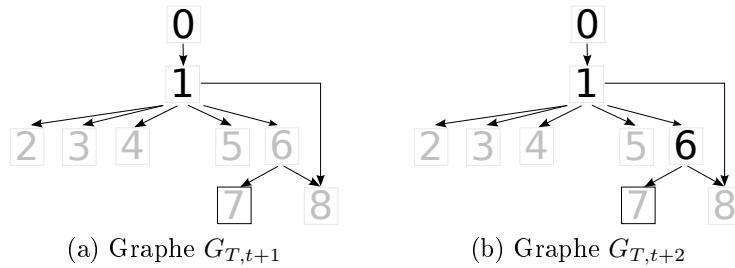


FIGURE 4.5 – Evolution de  $G_T$ , ROI et histogramme associés

#### 4.3.1 Recherche du nombre de classes à priori

Le moteur d'inférence détermine, à partir de  $G_T$ , la ROI et son nombre de classes pour une tumeur du foie sachant que le foie est segmenté :

$$\begin{aligned}
L_t(u) &= \{i \in (G_T^\infty(G_{T,t}^{-1}(u)) \cap (S \setminus S_t)) \mid (G_{T,t}^{-1}(i) \cap G_{T,t}^{-1}(u) \neq \emptyset)\} \cup G_{T,t}^{-1}(u) \\
L_t(7) &= \{i \in (G_T^\infty(G_{T,t}^{-1}(7)) \cap (S \setminus S_t)) \mid (G_{T,t}^{-1}(i) \cap G_{T,t}^{-1}(7) \neq \emptyset)\} \cup G_{T,t}^{-1}(7) \\
&= \{i \in (\{7, 8\} \cap \{1, 2, 5, 7, 8\}) \mid (G_{T,t}^{-1}(i) \cap \{6\} \neq \emptyset)\} \cup \{6\} \\
&= \{7, 8\} \cup \{6\}
\end{aligned} \tag{4.1}$$

Le nombre de classes à priori dans l'image est  $N_t(7) = |L_t(7)| = |7, 8, 6| = 3$ .



### 4.3.2 Identification des classes

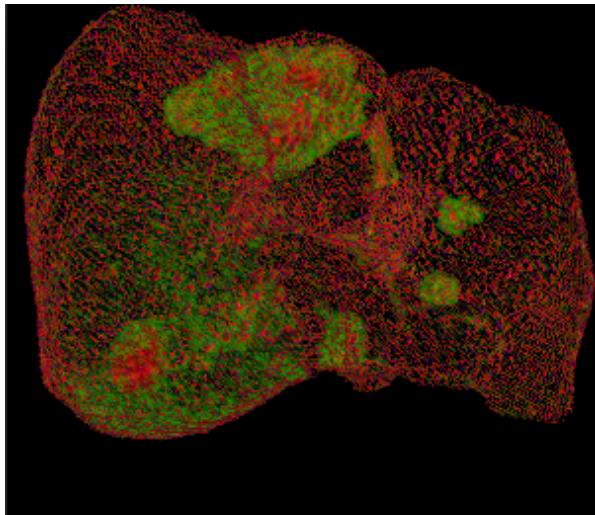
Connaissant le nombre de classes à priori, on segmente l'image en trois classes avec l'algorithme des *K-Means*. Pour savoir à quel type (e.g foie, tumeur) correspond chaque classe, le moteur d'inférence réorganise les classes trouvées à l'étape précédente par intensité croissante selon le graphe 4.3c.  $L_t(7) = 7, 8, 6$  devient  $O_t(u) = \text{ord}\{L_t(7)\} = 7, 6, 8$ . Les trois types sont maintenant associés aux trois classes ordonnées (voir tableau 4.2).

Types ordonnés $\text{ord}\{L_t(u)\}$	Tumeur (7)	Foie (6)	Réseau vasculaire (8)			
Classes <i>K-Means</i>	-28.0	90.0	91.0	122.0	123.0	258.0

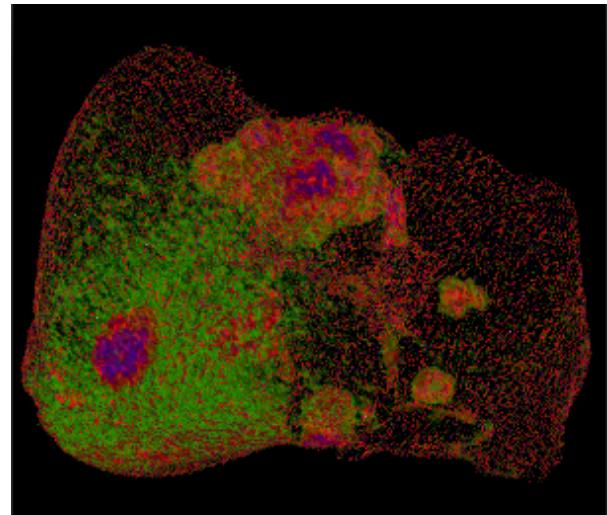
TABLE 4.2 – Ordonnancement des classes par intensité croissante.

### 4.3.3 Détermination du fenêtrage

Comme nous cherchons à optimiser le fenêtrage pour les tumeurs, nous calculons une fonction de transfert bornée par l'intervalle de la classe identifiée comme tumeur (fig. 4.6a) :



(a) Fenêtrage *K-Means* (-28, 90)



(b) Fenêtrage de référence à  $\mu \pm \sigma$  (51, 101)

FIGURE 4.6 – Rendu de différents fenêtrages et histogramme

On distingue au moins cinq tumeurs avec le fenêtrage déterminé par *K-Means* (fig. 4.6a), le rendu est plus proche du rendu optimal manuel (fig. 4.7b) que du rendu de référence (fig. 4.6b), c'est donc pour nous un résultat très satisfaisant puisqu'on améliore notablement le rendu grâce à la méthode proposée : pour ce cas l'objectif est atteint. On distingue néanmoins un voile rouge que l'on devine autour du foie, il caractérise probablement un problème de volume partiel.

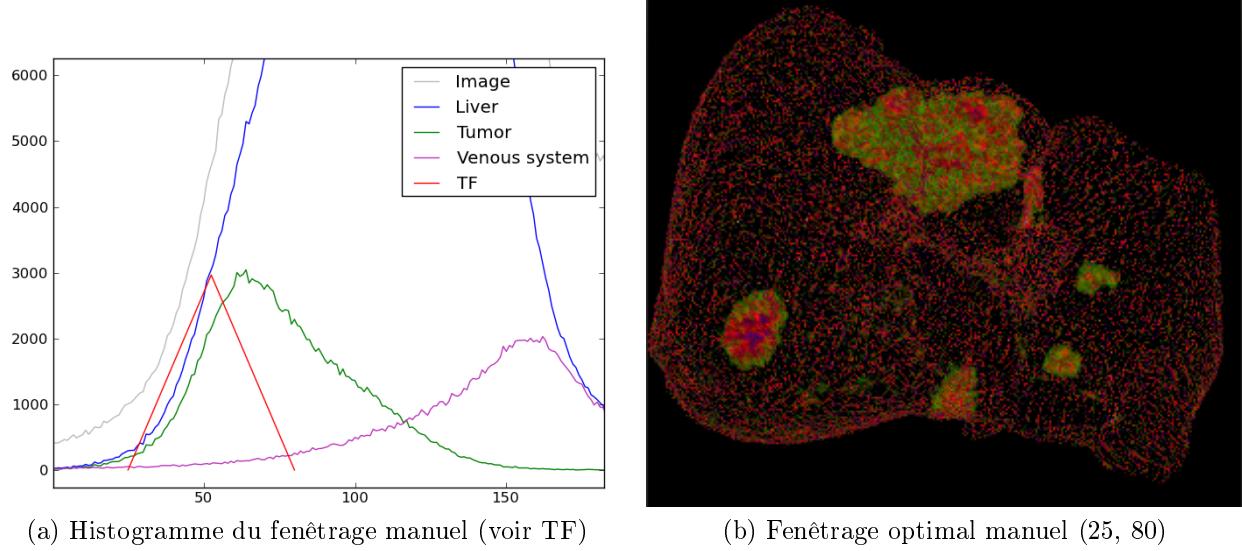


FIGURE 4.7 – Fenêtrage manuel

## 4.4 Scénario 2 : les vaisseaux hépatiques

Pour ce scénario, on considère une procédure séquentielle de segmentation où toutes les structures sont segmentées, à l’exception des tumeurs et des vaisseaux. Compte tenu de la remarque faite au sujet de la région “patient” qui est l’union stricte des structures qu’il contient suite à la simplification de ces données tests, on n’appliquera pas les formules définies pour déterminer le nombre de classes : on les déduit simplement de la configuration particulière de l’étude. Les trois classes correspondent respectivement aux tumeurs (7), au foie (6) et au réseau vasculaire ciblé (8).

### 4.4.1 Identification des classes

Connaissant le nombre de classes à priori, on segmente l’image en trois classes avec l’algorithme *K-Means* pour pouvoir associer chaque type à une classe, le moteur d’inférence réorganise les classes trouvées par intensité croissante selon le graphe 4.3c.  $L_t(8) = 7, 8, 6$  devient  $O_t(u) = \text{ord}\{L_t(8)\} = 7, 6, 8$ . Les trois types sont maintenant associés aux trois classes ordonnées (voir tableau 4.3).

Types ordonnés $\text{ord}\{L_t(u)\}$	Tumeurs (7)	Foie (6)	Vaisseaux (8)
Classes <i>K-Means</i>	-149.0	87.0	88.0
	125.0	126.0	755.0

TABLE 4.3 – Ordonnancement des classes par intensité croissante

La limite supérieure du foie (755) ne correspond pas à la réalité anatomique (voir le cas précédent avec une intensité maximale de 258 pour le foie), il y a certainement eu une imperfection lors de la création du masque. Cela souligne la nécessité d’avoir des masques parfaits.



#### 4.4.2 Détermination du fenêtrage

Cherchant à optimiser le fenêtrage pour le réseau vasculaire, nous calculons une fonction de transfert bornée par l'intervalle de la classe identifiée comme vaisseaux (entre 126 et 755).

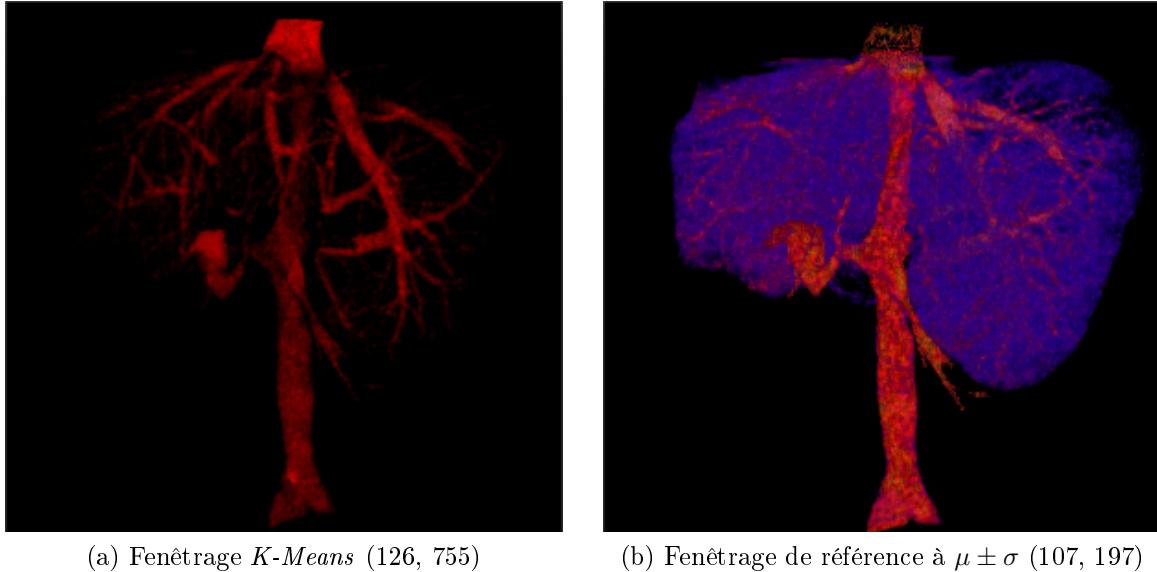


FIGURE 4.8 – Rendu de différents fenêtrages

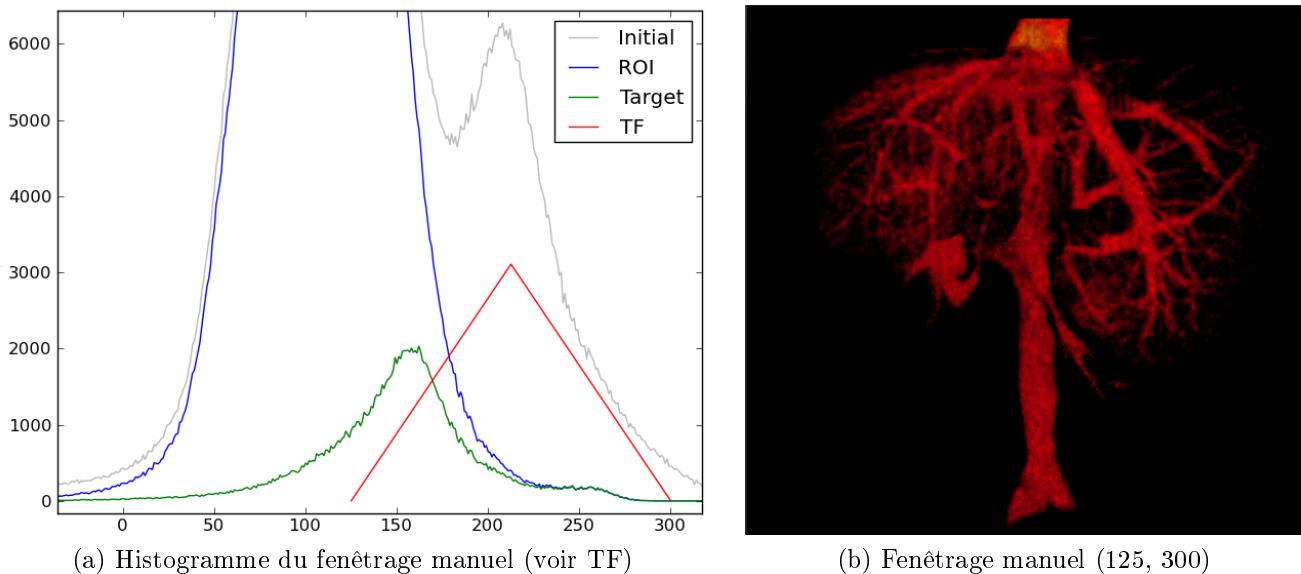


FIGURE 4.9 – Fenêtrages manuel

La comparaison du rendu de l'intervalle déterminé par *K-Means* (fig. 4.8a) et manuellement (fig. 4.9b), montre bien que la borne de 755 est aberrante puisque le rendu est semblable pour une valeur de 300 seulement. Malgré cette valeur érronée, le rendu reste très satisfaisant, l'objectif est de nouveau atteint pour ce cas.

# 5 Conclusion

## Bilan

L'apport des différentes connaissances à priori confirme, selon l'analyse quantitative des différents bénéfices chapitre 3, l'intérêt de notre méthode autant pour les images synthétiques que pour les images médicales. Il y a donc un intérêt certain à utiliser des connaissances à priori sur une image pour la traiter plus finement.

Un point incontournable de ce succès semble être l'application de masques à l'image afin de réduire l'analyse à une région d'intérêt contenant un minimum de données polluantes, il en résulte une rapidité de calcul accrue (moins de donnée et moins de classe à former). La segmentation est plus performante avec la connaissance à priori du nombre de classe, ce qui permet au final d'identifier plus précisément chaque classe pour appliquer un fenêtrage optimal à une ou plusieurs d'entre elles (visualisation améliorée).

## Perspectives et améliorations

Tout au long de ce travail, nous avons été confronté à des limites de la méthode pour lesquelles nous avons fait des choix et des hypothèses afin de pouvoir atteindre notre objectif principal d'optimisation du fenêtrage dans le temps imparti. Les connaissances à priori sur lesquelles reposent toute notre méthode doivent impérativement refléter la réalité de l'image sans quoi elles perdent leurs intérêts. En effet, si une structure est présente dans l'image mais pas dans le graphe conceptuel les inférences seront erronées ainsi que tous les traitements postérieurs. Une autre amélioration pourrait être de diviser les noeuds du graphe en sous nœuds selon si une même structure a différentes relations topologiques (e.g. les vaisseaux internes et externes au foie).

Outre les informations conceptuelles, les masques sont tout aussi importants malgré la difficulté à les créer automatiquement. C'est pourquoi nous travaillons à partir d'une base d'images et de masques existants. Notre méthode sera d'autant plus performante qu'il y aura de masques disponibles.

De part notre volonté de s'adapter à chaque spécificité de l'image, nous travaillerons uniquement avec des connaissances à priori non quantitatives, si on omet cet aspect et ses bénéfices, on pourrait introduire des notions quantitatives comme la multiplicité de chaque structure selon si elle est optionnelle ou non (e.g. pathologie) ou encore si elle peut apparaître plusieurs fois dans l'image auquel cas elle pourrait être segmentée que partiellement à différents instants. Un autre aspect quantitatif qui améliorerait les performances de segmentation pourrait être l'approximation des moyennes des classes pour paramétrier les algorithmes de segmentation.

Un dernier point à améliorer serait le calcul de la fonction de transfert utilisée pour le fenêtrage. C'est actuellement une fonction triangulaire, on pourrait envisager de la faire tendre vers la répartition réelle des pixels (une gaussienne) ou encore l'ajuster en fonction des structures segmentées voisine.

## Réflexion personnelle

Le travail bibliographique sur lequel s'appuie ce rapport est précieux pour moi en terme de contenu scientifique mais aussi de domaines d'applications. Il m'a permis d'orienter mon travail et, je l'espère, permettra de repousser les limites du traitement d'image guidé par des connaissances à priori. La partie formalisation reste pour moi le point le plus difficile de ce travail : la mise en équation d'un raisonnement n'était pas une activité naturelle pour moi. Les parties évaluation et application ont été, et reste, les plus fascinantes pour moi dans le sens où j'ai découvert au fil du stage comment et pourquoi on a besoin de connaître une image avant même de commencer à penser à la traiter. Ce fut pour moi une extraordinaire expérience mêlant recherche scientifique et traitement d'image qui m'a ouvert les portes d'un doctorat (sous réserve de financement).

## Annexes

# Annexe 1 : liste des notations

## Type

$S$	: ensemble des types à priori présent dans une image (e.g. foie, rate, vaisseau)
$S_t$	: ensemble des types qui ont été segmentés jusqu'à $t - 1$
$M(i)$	: multiplicité d'un type $i$ sachant que $i \in S$
$M_t(i)$	: multiplicité d'un type $i$ actif sachant que $i \in S_t$

## Image

$I$	: image initiale contenant des types (assimilés à des régions) distinctes
$I_t$	: image segmentée à $t$

## Région

$X(i)$	: ensemble des points de l'image associés à la région $i$ (initialement vide)
$X(\bar{i})$	: région restante (implicitement) après avoir retiré toutes les régions incluses dans $X(i)$
$X_t(i)$	: état de cette région à l'étape $t$ ( $X_t(i) \neq \emptyset$ si segmentée lors d'une étape antérieure).
$R_t(u)$	: ROI optimale au sens [10, Fasquel] d'un type $u$

## Graphe

$G = (S, A)$	: graphe orienté dont les nœuds sont l'ensemble $S$ et les arcs $A$
$G_t = (S_t, A)$	: graphe $G$ dont les nœuds $S_t \in S$ sont actifs (régions segmentées) à l'étape $t$
$G_T = (S, A_T)$	: graphe représentant les relations topologiques ( $A_T$ ) entre les types ( $S$ )
$G_P = (S, A_P)$	: graphe représentant les relations photométriques ( $A_P$ ) entre les types ( $S$ )

## Ensemble

$G^{\pm x}(i)$	: ensemble des successeurs (+)/prédécesseurs (-) à une distance $x \in \mathbb{N}$ du nœud $i$
$G^{\pm\infty}(i)$	: ensemble de tous les successeurs/prédécesseurs du nœud $i$ dans un graphe orienté $G$
$G_t^{\pm x}(i)$	: ensemble des successeurs/prédécesseurs actifs à une distance $x \in \mathbb{N}$ du nœud $i$
$G_t^{\pm\infty}(i)$	: ensemble de tous les successeurs/prédécesseurs actifs à une distance $\infty$ du nœud $i$
$G^{\pm\infty}(\{a, b\})$	: ensemble des successeurs/prédécesseurs de l'ensemble $\{a, b\} \Rightarrow G^{\pm\infty}(\{a\}) \cup G^{\pm\infty}(\{b\})$

## Information

$C$	: ensemble des informations à priori (graphe, image)
$C_t$	: ensemble des informations à priori $C$ à $t$

## Lobe

$L_t(u)$	: ensemble des types correspondants aux lobes de l'histogramme concernés par $u$
$N_t(u)$	: nombre de lobes (types) attendus dans l'image à $t$ (cardinalité de $L_t(u)$ )
$O_t(u)$	: ensemble des types de $L_t(u)$ ordonnés

# Bibliographie

- [1] David Arthur and Sergei Vassilvitskii. k-means++ : the advantages of careful seeding. In *SODA '07 : Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms*, pages 1027–1035, Philadelphia, PA, USA, 2007. Society for Industrial and Applied Mathematics. 15
- [2] Siddhartha Bhattacharyya, Ujjwal Maulik, and Paramartha Dutta. Multilevel image segmentation with adaptive image context based thresholding. *Applied Soft Computing*, 11(1) :946 – 962, 2011. 15
- [3] Matthew S. Brown, Laurence S. Wilson, Bruce D. Doust, Robert W. Gill, and Changming Sun. Knowledge-based method for segmentation and analysis of lung boundaries in chest x-ray images. 21, 22
- [4] J. Chabriais and B. Gibaud. Dicom, le standard pour l'imagerie médicale. *EMC - Radiologie*, 1(6) :577 – 603, 2004. 22
- [5] H. D. Cheng, Jim-Rong Chen, and Jiguang Li. Threshold selection based on fuzzy c-partition entropy approach. *Pattern Recognition*, 31(7) :857 – 870, 1998. 15
- [6] Nicolas Coudray, Jean-Luc Buessler, and Jean-Philippe Urban. Robust threshold estimation for images with unimodal histograms. *Pattern Recognition Letters*, 31(9) :1010 – 1019, 2010. 15, 21
- [7] Erik Cuevas, Daniel Zaldivar, and Marco Perez-Cisneros. A novel multi-threshold segmentation approach based on differential evolution optimization. *Expert Systems with Applications*, 37(7) :5265 – 5271, 2010. 15
- [8] A. Deruyver, Y. Hodéb, and L. Brun. Image interpretation with a conceptual graph : Labeling over-segmented images and detection of unexpected objects. *Artificial Intelligence*, 173 :1245–1265, 2009. 3, 4
- [9] Max J. Egenhofer and Matthew P. Dube. Topological relations from metric refinements. In *In Proceedings of GIS'2009*, pages 158–167. ACM, 2009. 3
- [10] J.-B. Fasquel, V. Agnus, J. Moreau, L. Soler, and J. Marescaux. An interactive medical image segmentation system based on the optimal management of regions of interest using topological medical knowledge. *Computer Methods and Programs in Biomedicine*, 82 :216–230, 2006. 1, 3, 4, 5, 6, 7, 13, 32
- [11] C. Hudelot, J. Atif, and I. Bloch. Fuzzy spatial relation ontology for image interpretation. *Fuzzy Sets and Systems*, 159 :1929–1951, 2008. 3
- [12] C. Hudelot J. Atif and I. Bloch. Adaptation de connaissances génériques pour l'interprétation d'images médicales : représentations par ontologies et par graphes et modélisation floue. ., 2007. 3

- [13] Roberto Marcondes Cesar Junior, Endika Bengoetxea, Isabelle Bloch, and Pedro Larrañaga. Inexact graph matching for model-based recognition : Evaluation and comparison of optimization algorithms. *Pattern Recognition*, 38(11) :2099–2113, 2005. 21
- [14] Masaharu Kobashi and Linda G. Shapiro. Knowledge-based organ identification from ct images. *Pattern Recognition*, 28(4) :475 – 491, 1995. 2
- [15] Peter Mildenberger, Marco Eichelberg, and Eric Martin. Introduction to the dicom standard. *Eur Radiol*, 12(4) :920–7, 2002. 22
- [16] A. Moreno, C.M. Takemura, O. Colliot, O. Camara, and I. Bloch. Using anatomical knowledge expressed as fuzzy constraints to segment the heart in ct images. *Pattern Recognition*, 41(8) :2525 – 2540, 2008. 2
- [17] Anna D. Peterson Ranjan Maitra and Arka P. Ghosh. A systematic evaluation of different methods for initializing the k -means clustering algorithm. *Computer Methods and Programs in Biomedicine*, 2010. 14, 18
- [18] S Ray and R H Turi. Determination of number of clusters in k-means clustering and application in colour image segmentation (invited paper). In *Proceedings of the 4th International Conference on Advances in Pattern Recognition and Digital Techniques (ICAPRDT'99)*, Philadelphia, PA, USA, 2007. Narosa Publishing House, New Delhi, India, ISBN : 81-7319-347-9. 18
- [19] E. Hiltbrandt W. Hinson N. Karstaedt P. Santiago W. T. Sobol S. Rossner, W. J. Bo and J. R. Crouse. Adipose tissue determinations in cadavers—a comparison between cross-sectional planimetry and computed tomography. *Computers in Industry*, 1990. 21
- [20] A. Sanfeliu, R. Alquézar, J. Andrade, J. Climent, F. Serratosa, and J. Vergés. Graph-based representations and techniques for image processing and image analysis. *Pattern Recognition*, 35(3) :639 – 650, 2002. 4
- [21] Gonzalez Woods and Eddins S. L. *Digital Image Processing*. Prentice Hall, third edition, 2008. 21
- [22] D. S. Hickey X. P. Zhu, D. R. Checkley and I. Isherwood. Accuracy of area measurements made from mr images compared with computed tomography. *Computers in Industry*, 1986. 21
- [23] Hui Zhang, Jason E. Fritts, and Sally A. Goldman. Image segmentation evaluation : A survey of unsupervised methods. *Computer Vision and Image Understanding*, 110(2) :260 – 280, 2008. 15

## Résumé

Mots clés : interprétation d'image, fenêtrage, moteur d'inférence, topologie, photométrie.

Ce rapport fait état de l'art en matière d'interprétation d'image guidée par des connaissances topologiques et photométriques à priori. L'utilisation d'informations à priori est un moyen d'anticiper le contenu d'une image et donc d'en optimiser son traitement. On représente ces connaissances sous forme de graphes conceptuels à partir desquels on infère le contenu de l'image. Il s'agit plus concrètement du nombre de classes de l'image et de leurs relations photométriques, à tout instant d'une procédure de segmentation itérative. Un point important de notre étude est la limitation à des connaissances non quantitatives de manière à appliquer un traitement spécifique à chaque image et à prendre en compte ses particularités.

Dans un second temps, nous quantifions les bénéfices de la méthode proposée à savoir, la diminution des données polluantes, le gain de temps de calcul ou encore sa robustesse.

Une dernière partie est consacrée à l'application à des images médicales de la région de l'abdomen dans lesquelles on fait apparaître clairement les tumeurs du foie et les vaisseaux hépatiques dans le but d'assister le diagnostic médical.

Keywords : image interpretation, windowing, inference engine, topology, photometry.

This report is the state of the art of image interpretation led by topological and photometrical informations. Using a priori informations is a method to anticipate the content of an image and then to improve the processing. We represent these informations as conceptual graphs and we infer image content. It is more precisely the number of classes in the image and their photometric relations, at each iteration of a segmentation procedure. One important point is that we consider only non quantitative informations in order to specify the image processing and consider its particularity.

Then we quantify the benefits of the proposed method namely polluted data reduction, processing time improvement and strength.

The last part of this work is an application to medical images from abdomen that we proceed in order to show clearly liver tumors and vessel system for diagnostic assistance purpose.